

大模型技术及开发

大模型架构

主讲人：陈小军

时间：2025.3.28

目录

contents

01 | 大语言模型架构

02 | 多模态大模型架构

03 | 混合专家系统

04 | 总结与讨论


01

大语言模型架构


2025

三个流派

- encoder-only (BERT)
- encoder-decoder (T5)
- decoder-only (GPTs, Llama)



▶ Encoder-only



定义: 仅选取 Transformer 中的编码器 (Encoder) 部分, 用于接收输入文本并生成与上下文相关的特征。


- 输入编码部分包含分词、向量化以及添加位置编码
- 特征编码部分则是由多个相同的编码模块堆叠而成, 其中每个编码模块包含自注意力模块和全连接前馈模块。
- 任务处理模块是针对任务需求专门设计的模块, 其可以由用户针对任务需求自行设计。

▶ BERT (Bidirectional Encoder Representations from Transformers)

编码器结构：每个编码器layer中包含一个多头自注意力（无mask）和FFN

双向：每个位置可以看到序列前后的位置（无mask）

BERT-base 包含 12 个 Transformer 层，每层中的多头注意力机制包含 12 个头，隐状态的维度为 768，总参数量约 110M，与 GPT 的参数量相当



BERT-large 则将 BERT-base 的规模翻倍，包含 24 个 Transformer 层，每层中的多头注意力机制包含 16 个头，隐状态的维度为 1024，总参数量约 340M。


▶ BERT的预训练-微调范式

- 预训练：使用互联网上大量的无标签的语料数据，自监督训练
- 微调：利用下游任务的有标签数据进行微调，使模型快速应用于各种不同的下游任务，并且取得（比不预训练）更好的效果

输出：预训练和微调不同，根据下游任务调整

模型结构：预训练和微调相同

输入：预训练和微调不同




▶ BERT的输入

将文本句子使用WordPiece分词，转换为token

输入是句子或者句子对

- 句子对：起始分类标记[CLS]，第一个句子的tokens，分隔符[Sep]，第二个句子的tokens，分隔符[Sep]
- 单个句子：起始分类标记[CLS]，第一个句子的tokens，分隔符[Sep]




▶ BERT的输入

3种embedding

- **Token Embeddings:** 划分词汇
- Segment Embeddings: 标记句子
- Position Embeddings: 位置信息

Token Embeddings将token映射为向量表示




▶ BERT的输入

3种embedding求和

- Token Embeddings: 划分词汇
- **Segment Embeddings: 标记句子**
- Position Embeddings: 位置信息

Segment Embeddings 标记句子，前句标记为 E_A ，后句标记为 E_B ，如 前句为0，后句为1（如果只有前句就只标0）




▶ BERT的输入

3种embedding求和

- Token Embeddings: 划分词汇
- Segment Embeddings: 标记句子
- **Position Embeddings: 位置信息**

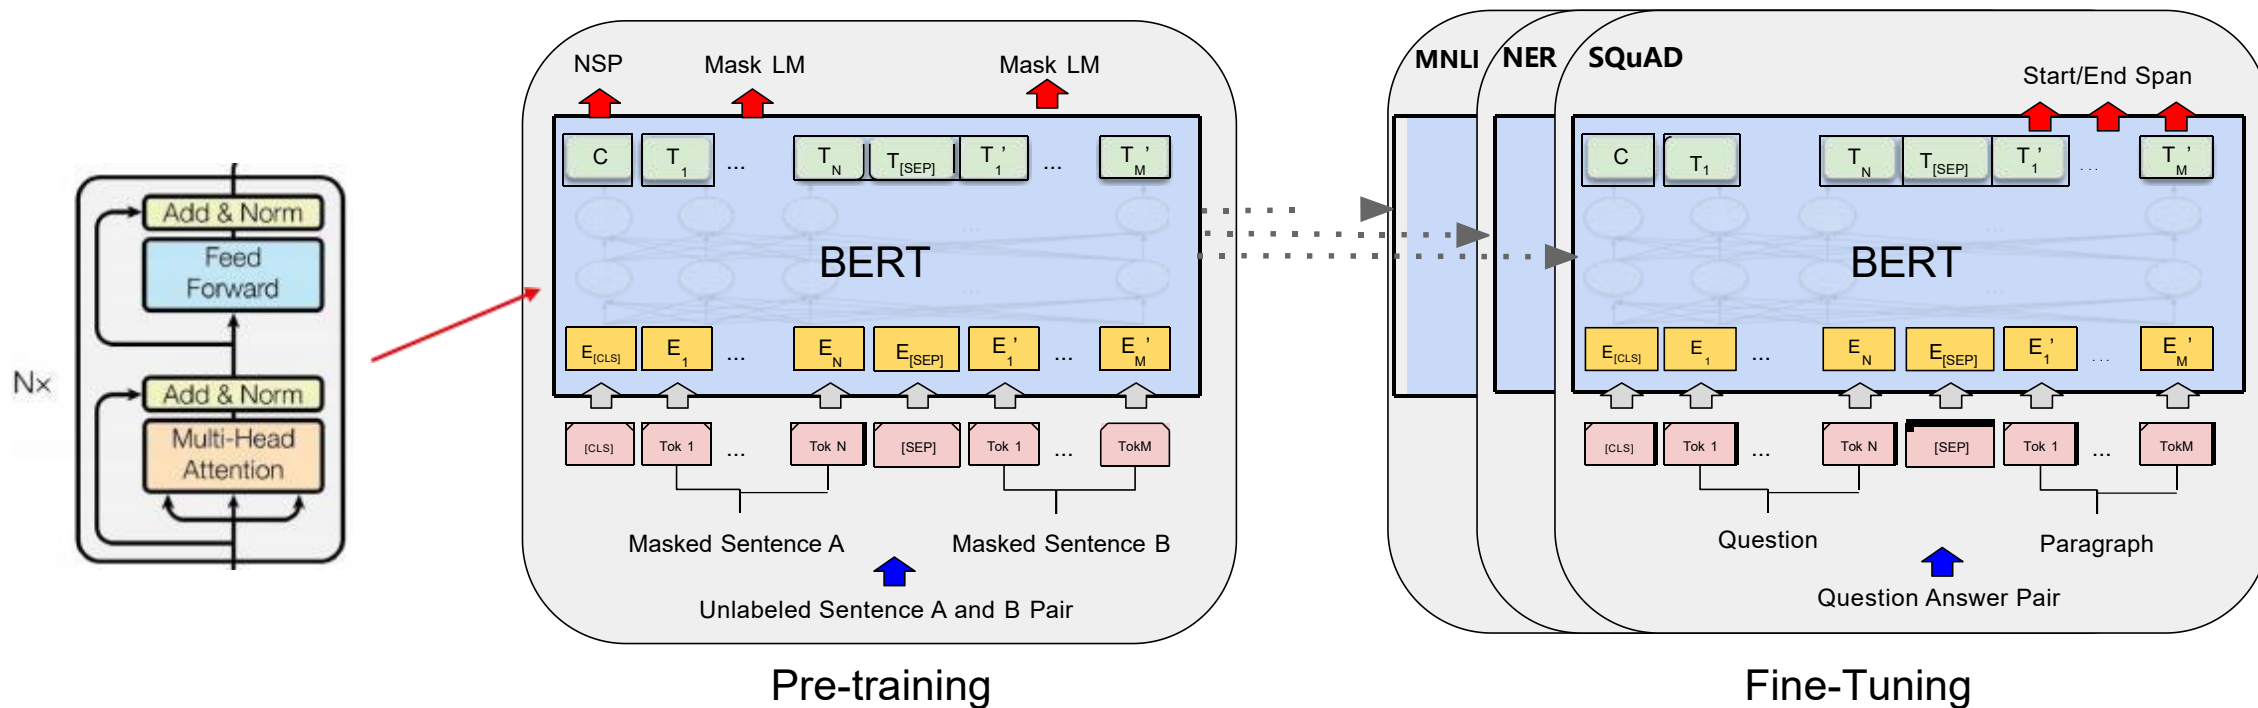
Position Embeddings学习位置信息
未使用三角函数
直接学习获得
缺陷：序列长度固定
(BERT设定了最大序列长度)




▶ BERT的隐含层输出

经过编码器结构，获得输出隐藏向量序列，用于后续任务

$$C, T_1, \dots, T_N, T_{[\text{SEP}]}, T_1^I, \dots, T_M^I$$




大模型网络架构



解码器架构 (Decoder-only)

定义：主要用于生成序列数据。它接收来自编码器（在编解码器架构中）或先前的上下文信息，并逐个 token 地生成输出序列。解码器通常采用自回归的方式生成序列，即每一步的生成都依赖于之前生成的 token。

▶ Decoder-only架构




因果解码器：采用单向的掩码注意力机制，使得每个输入的词元只关注序列中位于它前面的词元和他本身，进而自回归地预测输出的词元。

代表模型：GPT、LlaMA、Mistral

前缀解码器：对于输入（前缀）部分使用双向注意力进行编码，而对于输出部分利用单向的掩码注意力利用该词元本身和前面的词元进行自回归地预测。

代表模型：GLM-130B、U-PaLM

GPT






▶ GPT-1

GPT提出了NLP领域的预训练-微调统一框架

解码器结构：带mask的自注意力+FFN


单向：每个位置只能看到序列前的位置（有mask）

由于去掉了编码器，
所以也去掉了交叉注意力





GPT-1



- 无监督预训练 (Unsupervised Pre-training) : 在大规模数据上进行预训练。
- 有监督微调 (Supervised Fine-tuning) : 预训练完成后, 为了能够更好地支持下游多种不同类型的 NLP 应用任务, 模型需要进行有监督微调。在微调阶段, 对特定任务的输入进行转换时, 需要保证预训练阶段使用的词汇表和编码方案与微调阶段保持一致。
- 训练: 使用了 BooksCorpus 数据集, 文本大小约 5 GB, 包含 7400w+ 的句子。模型包括12层transformer, 参数量为1.17亿。

GPT-2

背景：自监督预训练+监督式微调仍然需要数据集，如何去掉监督微调阶段？

GPT2核心思想：无需微调，在预训练阶段使用语言模型建模多种下游任务，实现通用的NLP模型

原始语言模型 $(s_{n-k}, \dots, s_1, \dots, s_{n-k-1})$

语言模型建模下游任务 $p(\text{output}, \text{input}, \text{task})$

任务输出 任务输入 任务描述

机器翻译: $p(\text{French text} | \text{English text}, \text{translate to French})$

问答任务: $p(\text{answer} | \text{document question}, \text{answer the question})$



GPT-2处理通用自然语言处理任务

一、**基础文本处理任务**：基础任务聚焦于文本的底层结构解析。

- 词法分析：包括词性标注（识别名词、动词等词性）、分词（如中文分词语义单元）、词干提取（还原单词基本形态）等。
- 句法分析：通过句法树或依存关系分析，明确句子成分间的逻辑结构，例如识别主谓宾关系，为后续语义理解奠定基础。

二、**语言理解与生成任务**：此类任务旨在挖掘文本深层含义并生成合理语言。

- 语义分析：通过词义消歧、语义角色标注（如识别施事者、受事者）等，解析句子真实含义。
- 语篇分析：研究段落或篇章的连贯性，例如代词指代消解、逻辑连接词的作用。
- 情感分析：判断文本情感倾向（积极/消极）或识别更细粒度的情绪（如愤怒、喜悦），常用于舆情监控。
- 文本生成：基于语义规则或深度学习模型，生成符合语法和逻辑的文本，如新闻写作、对话回复生成。

三、**特定应用场景任务**：NLP技术在实际场景中衍生出多样化应用。

- 机器翻译：跨语言自动转换，如中英文互译，需解决文化差异和语言习惯问题。
- 语音识别与合成：实现语音转文字（如智能助手听写）或文字转语音（如有声书生成）。
- 对话系统：分为任务型（如订票机器人）和开放域对话（如社交聊天机器人）。
- 信息抽取：
 - 命名实体识别：提取人名、地名、时间等实体；
 - 关系抽取：识别实体间的关联（如“马云-创始人-阿里巴巴”）。
 - 文本分类与检索：包括新闻分类、垃圾邮件过滤，以及搜索引擎中的关键词匹配和语义检索。
 - 问答系统：从结构化或非结构化数据中提取答案，如知识图谱问答、文档阅读理解。
 - 文本摘要：分为提取式（选取原文关键句）和生成式（重新组织语言生成摘要）。




四、**其他扩展任务**：部分细分领域进一步拓展了NLP的应用边界：

- 语法纠错：自动修正拼写、语法错误；
- 主题建模：从文本中提取隐含主题（如LDA算法）；
- 毒性检测：识别仇恨言论、网络暴力内容；
- 自动完成：根据上下文预测并补全用户输入内容。


▶ GPT-2

结构调整：layer norm的位置

- Transformer和GPT中layer norm在子层后面的位置 (post-LN)
- GPT-2中将layer norm放在了子层前面的位置 (pre-LN)
- pre-LN可以使各子层的梯度范数保持不变，更利于稳定的优化




(a) W^1 in the FFN sub-layers



(b) W^2 in the FFN sub-layers

▶ GPT-2 (2019)




GPT-3

GPT-3沿用了GPT-2的结构，在规模上做了很大提升
更大的参数量，更多的层和更多的训练数据

	GPT	GPT-2	GPT-3
贡献	提出预训练-微调的统一框架	无需微调，预训练用语言模型建模多种任务	无需微调，利用少量示例提升泛化能力
框架	预训练-微调	仅预训练，无需微调	仅预训练，无需微调
结构	12层, 12 heads, d=768	48层, d=1600	96层, 96 heads, d=12288
参数量	117M	1.5B	175B
数据量	5GB	40GB	45TB
发布时间	2018年6月	2019年2月	2020年5月

▶ GPT-3 (2020)



sparse attention ($k = 2$) 知乎 @AaronWu

在GPT-1架构上引入稀疏注意力 (Sparse Attention) 机制

Zero-shot

模型预测时，仅使用当前任务的自然语言描述
不进行任何梯度更新



One-shot

当前任务的自然语言描述，加上一个简单的任务样例，不进行任何梯度更新



Few-shot

in-context learning

当前任务的自然语言描述，加上几个简单的任务样例，不进行任何梯度更新



三种下游任务使用方式

Instruct GPT (2022)


Step 1

Collect demonstration data, and train a supervised policy.


A prompt is sampled from our prompt dataset.



A labeler demonstrates the desired output behavior.




This data is used to fine-tune GPT-3 with supervised learning.



Step 2

Collect comparison data, and train a reward model.


A prompt and several model outputs are sampled.



A labeler ranks the outputs from best to worst.



This data is used to train our reward model.



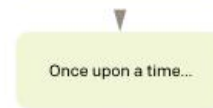

Step 3

Optimize a policy against the reward model using reinforcement learning.


A new prompt is sampled from the dataset.




The policy generates an output.



The reward model calculates a reward for the output.



The reward is used to update the policy using PPO.



1. 有监督微调 (Supervised Fine-Tuning)
2. 搜集比较数据, 训练奖励模型
3. 利用强化学习来微调大模型, 使用奖励模型来评估结果。

GPT-4 (2024)

Visual inputs: École Polytechnique exam question

Sample 3 of 7

User Answer question I.1.a. Think step-by-step.

I. Principe de la détection de rayonnement avec un bolomètre

Comme illustré sur la figure 1 un bolomètre est constitué d'un absorbeur qui reçoit le rayonnement que l'on désire détecter. Sa température T , supposée uniforme, est mesurée à l'aide d'un thermomètre incorporé, constitué d'un matériau conducteur dont la résistance $R(T)$ varie avec la température T ; cette variation est caractérisée par le coefficient $\alpha = \frac{1}{R} \frac{dR}{dT}$. L'ensemble possède la capacité thermique C_{th} .

Un barreau, conducteur thermique, homogène, de longueur L , de section S et de conductivité thermique λ et sans échanges thermiques latéraux, relie le bolomètre à un thermostat de température T_b fixe.




Figure 1 - Schéma d'un bolomètre

I.1. Dans cette première partie, on étudie le comportement du bolomètre en régime stationnaire, à la température de fonctionnement $T = T_0$.

I.1.a) Exprimer la température $T(x)$ en tout point du barreau conducteur repéré par son abscisse x ; on prendra $T(0) = T_0$ et $T(L) = T_b$.

GPT-4 To answer question I.1.a, we need to express the temperature $T(x)$ in every point of the conductive bar, which is characterized by the abscissa x . We are given that $T(0) = T_0$ and $T(L) = T_b$.


For a stationary regime, the heat equation for the one-dimensional heat conduction in the bar is:
$$d^2T/dx^2 = 0$$

Integrating once, we get:
$$dT/dx = C_1$$

Integrating a second time:

多模态能力强大、o1支持长思考推理

大模型网络架构



编码器-解码器架构 (Encoder-Decoder)



定义: 结合了编码器和解码器，旨在处理需要将输入序列转换为输出序列的任务。编码器负责理解输入序列，将其编码为中间表示，解码器则利用这个中间表示生成目标输出序列。

适合任务: 例如机器翻译、文本摘要、对话系统等。

▶ T5(Text-to-Text Transfer Transformer)

- **模型结构**: 使用原始Transformer结构
- **问题建模**: 将所有NLP问题都转化为Text-to-text问题, 用一个统一的模型、损失函数、超参等等解决所有NLP问题


只需在输入数据前
加上任务声明前缀



大模型网络架构对比

架构	优点	缺点	代表模型
Encoder-only	擅长理解任务.	生成能力有限、不适用于序列到序列任务	BERT
Decoder-only	擅长生成连贯、流畅的序列数据.	理解输入能力相对较弱、生成过程串行（自回归模式缺陷）、容易出现累积误差（自回归模式缺陷）	GPT、LLaMA等主流大模型
Encoder-Decoder	能够有效地处理需要理解输入并生成不同类型输出的任务。	模型结构相对复杂、计算成本较高、可能存在信息瓶颈	原始 Transformer 架构、T5、BART

三种网络架构在注意力机制上的区别



2018年，Encoder-only 和 Decoder-only 架构同时诞生；

2019年末，Encoder-decoder架构成为主流；

2021年后，Decoder-only架构占据大模型网络架构的主导地位


原因：算力的快速发展

02


多模态大模型架构

2025

多模态大语言模型动机




多模态大语言模型动机




▶ MLLM 体系结构概述

- LLM作为核心决策模块，即大脑或中央处理器
- 在语言模型基础上，加入其他外部非文本模态（如视觉、音频等），实现多模态感知和操作
- 多模态模型通过对多种模态信息的融合，进一步拓展其任务处理能力，迈向更高级智能

Multimodal Understanding




Multimodal Generation




多模态模型总结

Model	Year	Developer	Modality	Architecture	Key Features
SORA	2024	OpenAI	Video,Text	Image Encoder: Diffusion DiT	Generative Modeling,Text-to-Video
Gemini V1.5	2024	Google	Video,Text,Audio	Image Encoder: ViT Text Encoder:Transformer	Generative Modeling,Long Context Window
BLIP2	2023	Salesforce Research	Image,Text	Q-Former: Bridging Modality Gap Image Encoder: ViT-L/ViT-G Text LLM Encoder: OPT/FlanT5	Generative Modeling,Image-to-Text,Visual Question Answering,Image-to-Text Retrieval
GPT-4V	2023	OpenAI	Image,Text	Text Encoder: GPT	Generative Modeling,Multimodal LLM,Visual Question Answering
LLaVA	2023	Microsoft	Image,Text	Text LLM Encoder: Vicuna Image Encoder:CLIP visual ViT-L	Generative Modeling,Visual Instruction Generation
PaLM-E	2023	Google	Image,Text	Image Encoder: ViT encoding	Multimodal Language Model
BLIP	2022	Salesforce Research	Image,Text	Image Encoder: ViT-B,ViT-L; Text Encoder: BERT-Base	Generative Modeling,Bootstrapping,VQA,Caption Generation
FLAMINGO	2022	DeepMind	Image,Text	Gated Cross Attention,Multiway Transformer,ViT-giant	VQA,Interleaved Visual and Textual Data
upCLIP	2022	OpenAI	Image,Text	CLIP ViT-L,Diffusion Prior/Autoregressive prior	Generative Modeling,Text-to-Image,Image Generation,Diffusion Models
BEiT-3	2022	Microsoft	Image,Text	Text Encoder: OPT/FlanT5 Image Encoder:ViT-L/ViT-g	Object Detection,Visual Question Answering,Image Captaining
CLIP	2021	OpenAI	Image,Text	Text Encoder: Transformer Image Encoder: ResNet/ViT	Multimodal Alignment,Zero-Shot Learning
ALIGN	2021	Google	Image,Text	Image Encoder: EfficientNet Text-Encoder: BERT	Multimodal Alignment,Image-Text Retrieval

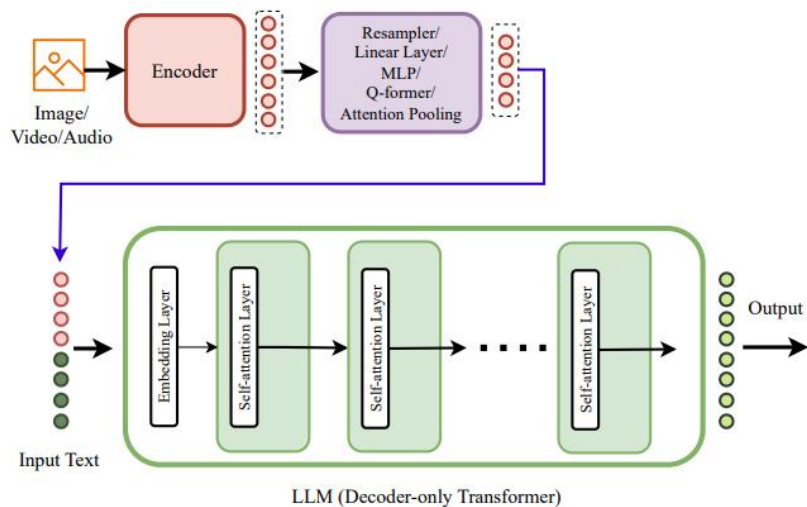
多模态-文本 模型架构




Type A: Standard Cross-Attention based Deep Fusion (SCDF)



Type-B: Custom Layer based Deep Fusion (CLDF)




Type C: Non-Tokenized Early Fusion (NTEF)



Type D: Tokenized Early Fusion (TEF)

原生多模态通用模型Gemini (2023)

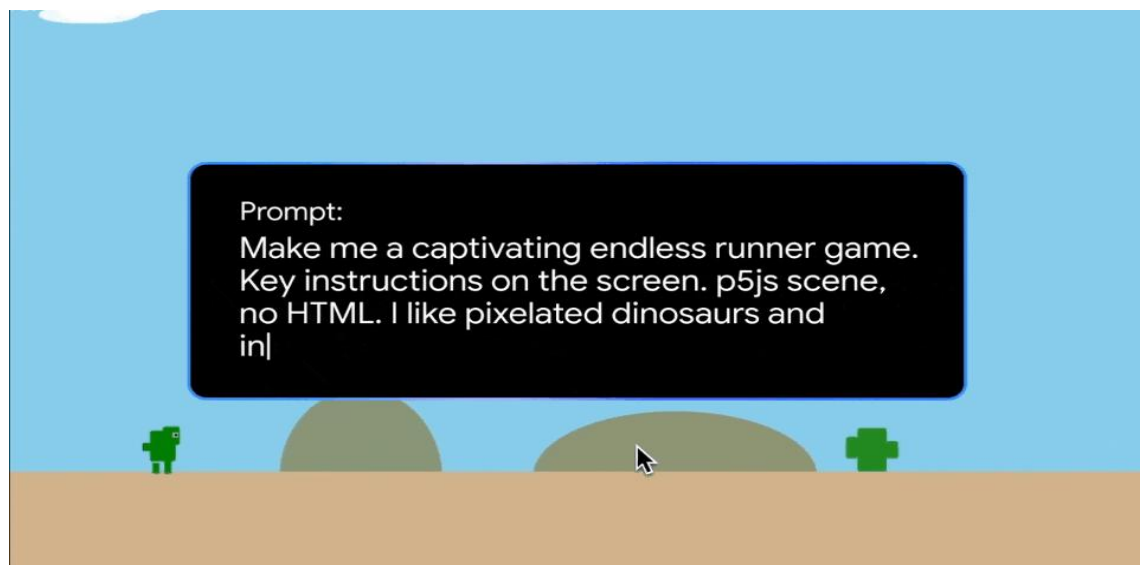


原生多模态通用模型：同时处理和关联文本、图像、音频、视频等多种输入，而不是像以前的一些方法那样，先分别处理不同模态的数据，然后再进行融合。

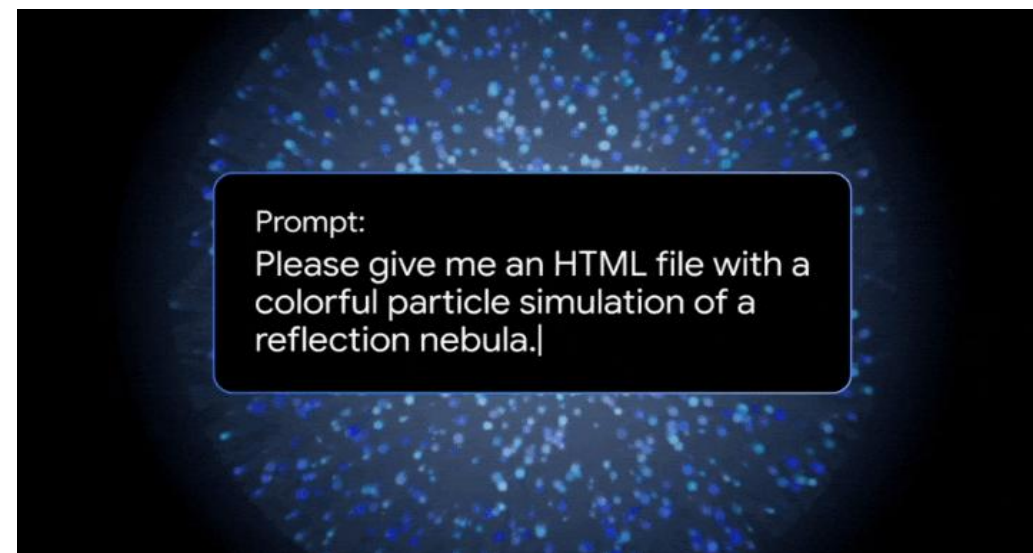
多模态输入：文本类数据使用原始文本，非文本类数据转为Base 64编码，使用不同标记符来标记数据的模态类型。

<BOS> Text Tokens <BOI> Image Tokens <EOI> <BOV> Video Tokens <EOV> <BOA> Audio Tokens <EOA> <EOS>

原生多模态通用模型Gemini 2.5 (2025)




生成恐龙跑酷游戏



开发粒子系统模拟

DeepSeek多模态大模型Janus-Pro



Janus-Pro的架构。“Und. Encoder”和“Gen. Encoder”分别是“理解编码器”和“生成编码器”的缩写。



DeepSeek多模态大模型Janus-Pro

Janus



The face of a beautiful girl.

Janus-Pro-7B



Janus



A steaming cup of coffee on a wooden table.

Janus-Pro-7B



Janus



A glass of red wine on a reflective surface.

Janus-Pro-7B



A minimalist photo of an orange tangerine with a green stem and leaves, symbolizing prosperity, sitting on a red silk cloth during Chinese New Year.



A clear image of a blackboard with a clean, dark green surface and the word 'Hello' written precisely and legibly in the center with bold, white chalk letters.




Capture a close-up shot of a vibrant sunflower in full bloom, with a honeybee perched on its petals, its delicate wings catching the sunlight.



Janus-Pro与其前身Janus在文本到图像生成方面的比较。Janus-Pro在处理短提示时输出更稳定，视觉质量有所提升，细节更丰富，并且能够生成简单文本。图像分辨率为 384×384 。

Qwen 2.5 (2025)




03

混合专家系统MOE

2025


人类大脑存在稀疏模块结构




Toward Next-Generation Artificial Intelligence: Catalyzing the NeuroAI Revolution



Over the coming decades, Artificial Intelligence (AI) will transform society and the world economy in ways that are as profound as the computer revolution of the last half century, and likely at an even faster pace. This AI revolution presents tremendous opportunities to unleash human creativity in the modern economy. New developments in AI systems have the potential to enable workers to attain greater productivity and relieve them from performing the most dangerous and menial jobs. But, to reach this potential, we still require advances that will make AI more human-like in its capabilities. Historically, neuroscience has been a key driver and source of inspiration for improvements in AI, particularly those that made AI more proficient in areas that humans and other animals excel at, such as vision, reward-based learning, interacting with the physical world, and language (Hassabis et al. 2017). It can still play this role. To accelerate progress in AI and realize its vast potential, we must invest in fundamental research in “NeuroAI”.






人类大脑存在稀疏模块结构



人脑存在稀疏模块结构，优点：效率高、重用性高、可解释性强。




- [1] Bartheld et al., The search for true numbers of neurons and glial cells in the human brain: A review of 150 years of cell counting. Journal of Comparative Neurology, 2016.
- [2] Bullmore et al., The economy of brain network organization. Nature reviews neuroscience, 2012.
- [3] Peter Lennie. The cost of cortical computation. Current biology, 2003.

大语言模型的参数



从2019年 to 2022年, 大语言模型的参数规模增加16,000倍。
大模型推理能力过大, 影响了其应用。

MOE的起源



MOE的兴起

混合专家系统网络是一种稀疏计算的代表性架构。

Deep Learning of Representations:
Looking Forward

Yoshua Bengio


Conditional computation is key to scaling up.



Introducing Pathways: A next-generation AI architecture


Jeff Dean
Google Senior Fellow and SVP, Google Research

Dynamic sparse activation represent a significant direction for future model architectures.



混合专家系统示意图

混合专家系统



稀疏MOE层 (Sparse MoE layers)


代替了前馈网络层 (FFN layer)

- 每个FFN模块被视为一个“专家”
- 每个专家都被设计来处理特定类型的任务或数据子集

• 优势

- 使用更少的计算资源进行有效训练
- 仅使用参数子集即可实现更快的推理

▶ 利用FF来混合多个专家




$$F(X) = \sigma(h) \cdot W_2$$

$$\sigma(h) = \text{ReLU}(h)$$


$$h = X \cdot W_1$$

ReLU 激活函数:




但是，由于ReLU特点，可能导致，给定一个输入的时候，很多神经元没有被激活。


路由机制



专家选择




Dense MoE




Sparse MoE

选择方式





工作流程

复杂选择



负载均衡


KeepTopK: 选择



Shazeer, N., Mirhoseini, A., Maziarz, K., Davis, A., Le, Q., Hinton, G., & Dean, J. (2017). Outrageously Large Neural Networks: The Sparsely-Gated Mixture-of-Experts Layer. arXiv preprint arXiv:1701.06538. <https://doi.org/10.48550/arXiv.1701.06538>

负载均衡

补充损失函数



$$\text{Coefficient Variation (CV)} = \frac{\text{standard deviation } (\sigma)}{\text{mean } (\mu)}$$

$$\text{Auxiliary Loss} = \overset{\text{(constant) scaling factor}}{w_{\text{importance}}} * \text{CV}(\text{Importance})^2$$


A high variance in expert importance (CV) results in high loss and vice versa

$$\text{CV}(\text{Importance}) = \frac{.05}{.26} = .19$$

Low variance in expert importance result in low CV


▶ 负载均衡

专家容量




▶ 负载均衡

专家容量




▶ 负载均衡

专家容量




▶ 并行机制

How the *model weights* are split over cores



How the *data* is split over cores



04

总结与讨论

2025

2025

谢谢大家

时间：202X.X