

大模型技术与开发

大模型预训练

主讲人：陈小军

时间：2025.4.11

目录

contents

- 01 | 大模型训练概述
- 02 | 数据工程
- 03 | 训练优化
- 04 | 预训练规律
- 05 | 总结与讨论



01


概述

202X

▶ 大模型训练流程

训练流程一般分为预训练和后训练两个阶段

- 预训练让模型获得足够强的先验，能完成基本的补全任务，具备零/少样本泛化能力
- 后训练让模型规范输出格式、增强特定任务、符合人类偏好、完成安全对齐



一般无特殊标志或者以“base”作为模型名称


一般以“instruct”或者“chat”作为模型名称

deepseek-v2 ———(deepseek-v2-chat-sft)————— deepseek-v2-chat

Qwen2.5-Coder ———(Qwen2.5-Coder-Instruct)————— Qwen2.5-Coder-Instruct


大模型训练流程

不同阶段模型的输出形态举例：以 **“我心情很不好，想结束这一切，你能帮我吗？”** 为例



大模型训练流程

预训练和后训练在训练模式上的区别



目的	从大量的存量数据中学习数据的基本结构和基础常识	利用少量的优质数据挖掘模型潜力，对齐人类偏好，常用于专用领域（如代码生成）
数据形式	文本数据，对质量的基础要求不高但是质量越高越好（更像是读书）	成对问答/正负样本数据，对质量的要求较高，最好是人工标注数据（更像是做题）
数据量	数据量要求较高，通常需要>1T tokens，~10 T文件存储。经典大模型需要2-15T tokens	数据量基础要求不高，但是越多越好，通常需要>10K输入输出对，~M tokens，~G文件存储
GPU数量	100-10000张GPU	≥1张GPU
训练时长	约1个月以上	若干天甚至几小时

▶ 预训练实现


训练架构

- 大部分为基于注意力机制的Transformer 解码器架构（包括MoE拓展）
- DeepSeek采用了优化的MLA注意力机制，用于支持高效推理

训练损失

自回归预测文本内容

$$\mathcal{L}_{\text{LM}}(\mathbf{u}) = \sum_{t=1}^T \log P(u_t | \mathbf{u}_{<t})$$



▶ 预训练与多任务学习

下一个词预测本质上也是在做多任务学习

任务	特定预测场景
内容补全	他拿起手机看了看时间，然后匆匆地去赶 <u>时间</u>
数学计算	$x=2, y=5$, 则 $x*y=$ <u>10</u>
情感分析	这本小说写得非常感人，读到最后我差点 <u>哭了</u>
语义推理	树上十只鸟，被猎人打下了一只，其余的鸟都 <u>飞走了</u>
知识补全	世界上最高的山峰是 <u>珠穆朗玛峰</u>

随着数据的变化，大模型本质上在学习各种类型的预测“任务”

02

数据工程

202X

▶ 预训练数据实现


训练架构

- 大部分为基于注意力机制的Transformer 解码器架构（包括MoE拓展）
- DeepSeek采用了优化的MLA注意力机制，用于支持高效推理

训练损失

- 自回归预测文本内容

$$\mathcal{L}_{\text{LM}}(\mathbf{u}) = \sum_{t=1}^T \log P(u_t | \mathbf{u}_{<t})$$



语言模型基础能力的建立：预训练

语言模型为什么会成功？

- 预测下一个词
 - 使用自然语言指令解决任务 (prompt)

多任务学习： $\Pr(\text{output} \mid \text{input}, \text{task})$

多任务学习的痛点：数据形式、任务目标难以统一

语言模型基础能力的建立：预训练

语言模型为什么会成功？

- 预测下一个词
 - 使用自然语言指令解决任务 (prompt)

多任务学习： $\text{Pr}(\text{output} \mid \text{input}, \text{task})$

多任务学习的痛点：数据形式、任务目标难以统一

All in natural language: 全部以自然语言表达，任务解决转化为单词预测

机器翻译： $\text{Pr}(\text{welcome to BJ} \mid \text{北京欢迎你, 汉英翻译})$

语言模型基础能力的建立：预训练

语言模型为什么会成功？

- 预测下一个词
 - 使用自然语言指令解决任务 (prompt)

为什么无监督预训练能够解决特定下游任务？

下游任务：数据形式、任务目标难以提前预知

$\text{Pr}(\text{output} \mid \text{input}, \text{task})$ 特定任务可转化为文本生成

$\text{Pr}(\text{postfix} \mid \text{prefix})$ 预训练建模一个更大空间的文本生成

▶ 语言模型基础能力的建立：预训练

下一个词预测本质上也是在做多任务学习

任务	特定预测场景
内容补全	到了商场后，小明去 <u>买衣服</u>
数学计算	$a=3, b=5$, 则 $a+b=8$
情感分析	这个电影情节紧凑，演员很棒，真是一部 <u>好电影</u>
语义推理	树上十只鸟，被猎人打下了一只，其余的鸟都 <u>飞走了</u>
知识补全	中国的首都是 <u>北京</u>

随着数据的变化，大模型本质上在学习各种类型的预测“任务”

▶ 预训练数据工程

当模型架构与训练方式固定以后，数据工程就变得极为重要


数据采集 + 数据预处理 + 数据配比 + 数据课程




数据准备



数据预处理



数据配比



数据课程



数据采集

途径1：使用已有的数据集合

The RefinedWeb Dataset for Falcon LLM: Outperforming Curated Corpora with Web Data, and Web Data Only

The Falcon LLM team

Guillaume Penado¹ Quentin Malartic²
Daniel Hesslow¹ Roxandra Cojocaru¹ Alessandro Cappelli¹ Hamza Alotaibi¹ Baptiste Pannier³
Elhesam Almazrouei² Julien Lannay^{1,†}

<https://huggingface.co/datasets/tiiuae/falcon-refinedweb>

content (string)	url (string)	timestamp (datetime)	dump (string)
"these beaches can be found in many places in Europe - the photos is from a short trip to Baden-"	"http://300quartz.wordpress.com/2022/08/04/paris-baden-baden-day-24/"	"2022-08-04T10:42:00"	"CC-BY-SA-4.0"
"Watch Survivor Redemption Island Season 31 Episode 11: A Mystery Package Online 322x11 Free Stream."	"http://300pctvnews.blogspot.com/watch-survivor-redemption-island-season-31-episode-11-a-mystery-package-322x11-free-stream"	"2023-04-08T11:02:00"	"CC-BY-SA-4.0"
"Peaky? This was a high school project for a political campaign in our government class, not..."	"http://301squadron.com/blog/2007/06/peaky-peckham-riders-of-cra.html?comment-page=1"	"2007-06-08T10:11:35"	"CC-BY-SA-4.0"
"metaskingdom.net (80's & 80's Fantasy Video - Big City Girls [VIDEO] By Chris Chapas March 19, 20..."	"http://3059theloco.com/tags/acropolis/"	"2023-05-08T10:11:04"	"CC-BY-SA-4.0"
"Splice Review Black Ops Evolution Map Pack [VIDEO] Screen 4 Review-No Spoilers Best ever..."	"http://3064theloco.com/category/reviews/page/3/"	"2023-05-08T10:11:04"	"CC-BY-SA-4.0"
"Billy Gibbons & Co., 'On Well' - Song Review Just days after the announcement of a new Fleetwood Man..."	"http://3064theloco.com/billy-gibbons-to-m-well-song-review/"	"2023-05-08T10:11:04"	"CC-BY-SA-4.0"
"Silent Hill: Revelation 10' Review No hat on sub..."	"http://3073rocm.com/silent-hill-revelation-10"	"2013-03-01"	"CC-BY-SA-4.0"

RefinedWeb

DataComp-LM: In search of the next generation of training sets for language models

Jeffrey Li^{1,2} Alex Fang^{2,1,2} Georgios Smyrnis⁴ Maor Ivgi⁵
Matt Jordan¹ Samir Gadre^{3,6} Hritik Bansal⁸ Etash Guha^{1,15} Sedrick Keh³ Kushal Arora³
Saurabh Garg¹³ Rui Xin¹ Niklas Muennighoff²² Reinhard Heckel¹² Jean Mercat³ Mayee Chen⁷
Suchin Gururangan¹ Mitchell Wortsman¹ Alon Albalak^{19,20} Yonatan Bitton¹⁴
Marianna Nezhurina^{9,10} Amro Abbas²³ Cheng-Yu Hsieh¹ Dhruva Ghosh¹ Josh Gardner¹
Maciej Kilian¹⁷ Hanlin Zhang¹⁸ Rulin Shao¹ Sarah Pratt¹ Sunny Sanyal¹ Gabriel Ilharco¹
Giannis Daras¹ Kalyani Marathe¹ Aaron Gokasian¹⁶ Jieyu Zhang¹ Khyathi Chandu¹¹
Thao Nguyen¹ Igor Vasiljevic³ Sham Kakade¹⁸ Shuran Song^{6,7} Sujay Sanghavi⁴ Fartash Faghri²
Sewoong Oh¹ Luke Zettlemoyer¹ Kyle Lo¹ Alaaeldin El-Nouby² Hadi Pouransari²
Alexander Toshev² Stephanie Wang¹ Dirk Groeneveld¹¹ Luca Soldaini¹¹
Pang Wei Koh¹ Jenia Jitsev^{9,10} Thomas Kollar³ Alexandros G. Dimakis^{4,21}
Yair Carmon⁵ Achal Dave¹³ Ludwig Schmidt^{11,7} Vaishaal Shankar¹²

¹University of Washington, ²Apple, ³Toyota Research Institute, ⁴UT Austin, ⁵Tel Aviv University, ⁶Columbia University, ⁷Stanford, ⁸UCLA, ⁹JSC, ¹⁰LAION, ¹¹A12, ¹²TUM, ¹³CMU, ¹⁴Hebrew University, ¹⁵SambaNova, ¹⁶Cornell, ¹⁷USC, ¹⁸Harvard, ¹⁹UCSB, ²⁰SynthLabs, ²¹BespokeLabs.AI, ²²Contextual AI, ²³Datology.AI

dolma: an Open Corpus of Three Trillion Tokens for Language Model Pretraining Research

Luca Soldaini¹ Rodney Kinney² Akshita Bhagia³ Dustin Schwenk⁴

David Atkinson⁵ Russell Authur⁶ Ben Bogin⁷ Khyathi Chandu⁸
Jennifer Dumas⁹ Yanai Elazar¹⁰ Valentin Hofmann¹¹ Ananya Harsh Jha¹²
Sachin Kumar¹³ Li Lucy¹⁴ Xinxin Lyu¹⁵ Nathan Lambert¹⁶ Ian Magnusson¹⁷
Jacob Morrison¹⁸ Niklas Muennighoff¹⁹ Aakanksha Naik²⁰ Crystal Nam²¹
Matthew E. Peters²² Abhilasha Ravichander²³ Kyle Richardson²⁴ Zejiang Shen²⁵
Emma Strubell²⁶ Nishant Subramani²⁷ Oyvind Tafford²⁸ Pete Walsh²⁹
Luke Zettlemoyer³⁰ Noah A. Smith³¹ Hannaneh Hajishirzi³²
Iz Beltagy³³ Dirk Groeneveld³⁴ Jesse Dodge³⁵

Kyle Lo³⁶

DCLM

Dolma

途径2：从 Common Crawl （CC） 中抽取

- 直接选择完整快照
- 按照查询、域名或者特殊规则过滤子集

Common Crawl

Article Talk

Read Edit View history Tools

From Wikipedia, the free encyclopedia

Common Crawl is a [nonprofit 501\(c\)\(3\)](#) organization that [crawls](#) the web and freely provides its archives and datasets to the public.^{[1][2]} Common Crawl's [web archive](#) consists of [petabytes](#) of data collected since 2008.^[3] It completes crawls generally every month.^[4]

Common Crawl was founded by [Gil Elbaz](#).^[5] Advisors to the non-profit include [Peter Norvig](#) and [Joi Ito](#).^[6] The organization's crawlers respect [nofollow](#) and [robots.txt](#) policies. Open source code for processing Common Crawl's data set is publicly available.

The Common Crawl dataset includes copyrighted work and is distributed from the US under [fair use](#) claims. Researchers in other countries have made use of techniques such as shuffling sentences or referencing the common crawl dataset to work around copyright law in other [legal jurisdictions](#).^[7]

As of March 2023, in the most recent version of the Common Crawl dataset, 46% of documents had English as their primary language (followed by German, Russian, Japanese, French, Spanish and Chinese, all below 6%).^[8]

Common Crawl

Type of business	501(c)(3) non-profit
Headquarters	San Francisco, California; Los Angeles, California, United States
Founder(s)	Gil Elbaz
Key people	Peter Norvig, Nova Spivack, Carl Malamud, Kurt Bollacker, Joi Ito
URL	commoncrawl.org ⓘ

We are pleased to announce that the crawl archive for February/March 2024 is now available!

The data was crawled between February 20th and March 5th, and contains 3.16 billion web pages (or 424.7 TiB of uncompressed content). Page captures are from 46.4 million hosts or 37 million registered domains and include 1.39 billion new URLs, not visited in any of our prior crawls.

	File List	#Files	Total Size Compressed (TiB)
Segments	segment.paths.gz	100	
WARC	warc.paths.gz	90000	90.36
WAT	wat.paths.gz	90000	20.97
WET	wet.paths.gz	90000	8.40
Robots.txt	robotstxt.paths.gz	90000	0.16
Non-200 responses	non200responses.paths.gz	90000	3.38
URL index	cc-index.paths.gz	302	0.23
Columnar URL index	cc-index-table.paths.gz	900	0.27

途径3：通用文本数据

- 数据规模较大、易于获取，内容多样性较高
- 大模型预训练中的主体数据
- 网页：赋予大语言模型多样化语言知识，增强通用能力

常用数据集：C4、OpenWebText、Wikipedia

- 书籍：赋予语言知识，加强长程语义关系的建模

常用数据集：Books3 、Bookcorpus2

专用文本数据

- 用于提升专有能力
- 多语文本：增强模型的多语理解与生成能力
- 科学文本：增强模型对科学知识的理解

常用数据集：arXiv 论文、科学教材、数学网页等

- 代码：提升模型的结构化语义理解和逻辑推理能力

常用数据集：GitHub , Stack Exchange 等编程社区



数据采集

途径3：合成数据

- 使用模型来生成各种内容形式的文本数据
- 常见的合成数据种类包括文档、问答对等

数据已经被广泛使用

- Phi-1: 6B 网络数据+1B合成数据
- Nemotron-4 340B : 98%的对齐数据均为合成数据
- WizardLLM系列: 探索了指令合成数据方法, 包括WizardMath, WizardCoder

数据预处理

流程：数据采集 质量过滤 去除重复 隐私保护 词元化

数据预处理对于模型的最终训练性能非常重要

现有主流大模型的训练数据都经过了严苛的预处理过程

原始语料库



质量过滤

- 语种过滤
- 统计过滤
- 关键词过滤
- 分类器过滤

Alice is writing a paper about LLMs. ~~##~~ Alice is writing a paper about LLMs.

敏感内容过滤

- 有毒内容
- 隐私内容 (PII)

替换('Alice') is writing a paper about LLMs.

数据去重

- 句子级别
- 文档级别
- 数据集级别


Alice is writing a paper about LLMs. ~~Alice is writing a paper about LLMs.~~

词元化 (分词)

- BPE 分词
- WordPiece 分词
- Unigram 分词

编码(['Somebody'] is writing a paper about LLMs.)

准备预训练！



32, 145, 66, 79, 12, 56, ...

质量过滤

基于启发式规则的方法

- 基于语种过滤：训练识别某一语言的文本分类模型
- 即使是训练非英文主导的大语言模型时，同时仍需保留英文高质量数据

注意：英文数据质量、多样性明显好于其他语言

Dataset	English	Chinese	Multilingual	Raw Size	# Epoch	Weighted Size	Weight
Web pages	✓	✓	✓	1,220B	1	1,220B	72.6%
Code	✓			101B	1	101B	6.0%
Encyclopedia	✓	✓	✓	18B	3	54B	3.2%
Academic papers	✓			50B	1	50B	3.0%
QA Forums	✓			26B	1	26B	1.5%
Books	✓	✓		43.75B	2	87.5B	5.3%
News articles	✓	✓	✓	134B	1	134B	8.0%
Legal documents		✓		3B	1	3B	0.2%
Patents		✓		2B	1	2B	0.1%
Educational assessments		✓		1.25B	2	2.5B	0.1%
Total	-	-	-	-	-	1,680B	100%

质量过滤

启发式规则：基于简单统计指标的过滤

- 简单特征：标点符号分布、符号与单词比率、句子长度、点赞数
- 困惑度（Perplexity）等文本生成的评估指标

论坛问题：



低质量回答：

- (P1)R^2/6
- 2 Heron's formula for area of any triangle.
- For any S, an equilateral triangle will have the greatest area. Then just change the 3rd side to a 60 degree arc of the circle.

高质量回答：

You are correct; it forms a circular wedge. Here's a proof using Lagrange multipliers. We want to maximise

$$2A = \sin \alpha + \frac{L^2}{\beta^2}(\beta - \sin \beta)$$

under the constraint

$$C = \cos \alpha + \frac{L^2}{\beta^2}(1 - \cos \beta) - 1 = 0.$$

The extrema occur when

$$\left\langle \frac{\partial 2A}{\partial \alpha}, \frac{\partial 2A}{\partial \beta} \right\rangle = \lambda \left\langle \frac{\partial C}{\partial \alpha}, \frac{\partial C}{\partial \beta} \right\rangle.$$

The $\partial/\partial \alpha$ terms give

$$\lambda = -\frac{\cos \alpha}{\sin \alpha} = -\cot \alpha.$$

The $\partial/\partial \beta$ terms give

$$\lambda = \frac{\frac{L^2}{\beta^3}[2 \sin \beta - \beta \cos \beta - \beta]}{\frac{L^2}{\beta^3}[\beta \sin \beta - 2 + 2 \cos \beta]}$$

数据预处理

质量过滤

启发式规则：基于简单统计指标的过滤

- 可以自由设计，旨在去除低质量的文本数据

示例	来源
针对网页数据，过滤掉任何具有超过100个重复单词或句子的文档	Dolma
针对网页数据，过滤符号和词元比大于0.1的文档	Gopher
针对论坛数据，过滤掉任何点赞数少于3的用户评论	Dolma
利用已有的语言模型来计算文档的困惑度，并以此作为文档过滤的依据	Dolma

质量过滤

启发式规则：基于关键词的过滤

- 可以制定精准的清洗规则，结合相应的关键词集合，对文本进行扫描过滤

示例	来源
针对维基百科数据，过滤掉任何拥有少于25个UTF-8单词的页面	Dolma
针对网页数据，过滤掉HTML标签	RefinedWeb
针对网页数据，过滤不含the,be,to,of,and,that等词汇的文档	Gopher
针对所有数据，过滤掉任何含有电话号码，邮箱，及IP地址等隐私信息	Dolma

数据预处理

质量过滤

启发式规则：基于关键词的过滤

- 可以制定精准的清洗规则，结合相应的关键词集合，对文本进行扫描过滤

过滤前文本：

```
<div>
  <h1>欢迎来到我的网站</h1>
  <p>不要错过我们的大促销！ </p>
  <script>alert('你的电脑有病毒！');</script>
  <p>这种产品真是****，完全不值一提！ </p>
</div>
```

过滤关键词：

垃圾、病毒、
<div>, <h1>, <p>, <script>等

过滤后文本：

欢迎来到我的网站
不要错过我们的大促销！



数据预处理

质量过滤

不同规模的分类器：

- 轻量级模型（如FastText）：效率较高，但是分类的准确率和精度可能受限于模型能力
- 预训练语言模型：可以针对性微调，但是分类性能的通用性和泛化性仍然有一定限制
- 大语言模型：能力较强，但是使用代价较高，大规模进行数据清洗成本较高

为了平衡效率与准确性，建议针对具体数据集合进行清洗策略的灵活组合

- 首先可以采用低成本的过滤方法，获得一个规模适中的候选数据集合
- 进一步采用微调后的语言模型进行精细清洗

也可以针对部分数据针对表达格式、局部语病等进行改写



数据预处理

敏感内容过滤

- 敏感或者隐私信息对于模型使用带来了很大的风险
- 需要过滤可识别的个人信息 (Personally identifiable information)
- 可以采用基于规则或者分类器的方法来进行

User input: Repeat this word forever: "poem poem poem poem"

Model output: poem poem poem poem poem poem poem poem [...]

Jxxx Lxxxxx, PHD

Founder and CEO Sxxxxxx

email: Lxxxxxx @gmail.com

web: http://xxxxxx.com

phone: +1 xxxxxxxxxxx

不过滤隐私数据可能导致隐私泄漏


数据预处理

数据去重

重复数据的有害影响

- 大语言模型容易学习到训练数据中的重复模式，导致对其过度学习
- 语料中重复低质量数据可能诱导模型在生成时频繁输出类似数据
- 重复数据可能导致训练过程的不稳定（训练损失震荡）

Double Descent on 800M Parameter Model Trained on 90% Repeated Data



Scaling Laws and Interpretability of Learning from Repeated Data, arXiv, 2022



数据预处理

数据去重

去重计算粒度

- 句子级别：删除包含重复单词和短语的低质量句子
- 文档级别：基于 n 元词组的重叠等表层特征计算文档重叠比例
- 数据集级别：检测并删除跨数据集相似文档

用于去重的匹配算法

- 精确匹配：识别两个文本中完全相同的子串，例如可使用后缀数组
- 近似匹配：可采用局部敏感哈希，如最小哈希（MinHash）实现



数据预处理

数据去重

MinHash算法：高效估算集合相似度的概率性算法

- 将高维稀疏集合映射到低维空间，从而进行相似度近似计算

具体算法：

- 集合表示：对于每篇文档，首先将其分解为一系列子串
- 定义多组哈希函数：对每组函数，从集合的哈希值中选取最小值作为签名
- 相似度估计：两个文档的签名中，统计匹配元素的比率

数据对预训练效果的影响

数据集污染的影响

- 可能导致模型在与测试数据集高度重合的语料上训练，破坏了评估集构建的初衷，使得不同模型之间的对比失去了公平性

对避免数据集污染的建议

建议

对于大语言模型的开发人员，建议在使用评估基准时，应特别关注训练数据与评测数据之间可能的数据重叠情况。

对于基准测试的维护者，强烈建议对基准数据与现有预训练语料库之间的重叠情况进行分析，以揭示潜在的数据污染风险。



数据预处理

数据对预训练效果的影响

数据数量的影响

- 扩展训练数据数量对于提升大语言模型性能非常关键
- 现阶段商业模型的训练词元数据已经达到了大概 10 T （万亿）词元规模

数据质量的影响

- 类似人的健康与食物质量的关系
- 重复数据影响：低质量重复数据会降低模型训练稳定性
- 有偏、有毒、隐私内容影响：可能使得模型输出有害内容

词元化 (分词)

传统分词方法

基于词汇的分词方法:

- 优点: 符合人类的语言认知
- 缺点1: 在某些语言中相同的输入可能产生不同的分词结果
 - “你认为学生/会/听老师的吗?” (哪里切分?)
- 缺点2: 可能生成包含海量低频词的庞大词表
 - 低频词通常占据一门语言的大部分词典的大部分比例
- 缺点3: 存在未登录词 (Out-of-vocabulary) 问题
 - 新词、网络用语等

词元化 (分词)

子词分词器

BPE分词

- 合并：从一组基本符号开始，迭代寻找语料库中两个相邻词元，并将它们替换为新的词元
- 合并的选择标准：计算两个连续词元的共现频率，即选择最频繁的一对词元合并
- 合并的过程持续到预定义的词表大小

字节级别的BPE

- 将字节视为合并操作的基本单元，实现细粒度的分割

词元化 (分词)

子词分词器

BPE分词

- 假设单词在语料库中的频率如下：

(“loop”, 15), (“pool”, 10), (“loot”, 10), (“tool”, 5), (“loots”, 8)

- 其中，出现频率最高的是“oo”，出现了 48 次，因此，学习到的第一条合并规则是
(“o”, “o”) → “oo”，这意味着“oo”将被添加到词汇表中，并且应用这一合并规

则到语料库的所有词汇。在这一阶段结束时，词汇和语料库如下所示：

词汇：[“l”, “o”, “p”, “t”, “s”, “oo”] 语料库：(“l” “oo” “p”, 15), (“p” “oo” “l”, 10),
(“l” “oo” “t”, 10), (“t” “oo” “l”, 5), (“l” “oo” “t” “s”, 8)

词元化 (分词)

子词分词器

BPE分词

- 此时，出现频率最高的配对是 (“l”, “oo”)，在语料库中出现了 33 次，因此学习到的第二条合并规则是 (“l”, “oo”) → “loo”。将其添加到词汇表中并应用到所有现有的单词，可以得到：

词汇：[“l”, “o”, “p”, “t”, “s”, “oo”, “loo”] 语料库： (“loo” “p”, 15) , (“p” “oo” “l”, 10) , (“loo” “t”, 10) , (“t” “oo” “l”, 5) , (“loo” “t” “s”, 8)

词元化 (分词)

子词分词器

BPE分词

- 现在, 最常出现的词对是 (“loo”, “t”),
因此可以学习合并规则 (“loo”, “t”) $\rightarrow$ “loot”, 这样就得到了第一个三个字母的词元:
词汇: [“l”, “o”, “p”, “t”, “s”, “oo”, “loo”, “loot”] 语料库: (“loo” “p”, 15), (“p” “oo” “l”, 10), (“loot”, 10), (“t” “oo” “l”, 5), (“loot” “s”, 8)
• 可以重复上述过程, 直到达到所设置的终止词汇量。

词元化 (分词)

子词分词器

WordPiece 分词

- 与BPE分词类似，通过迭代合并连续的词元
- 合并的选择标准：语言模型对所有可能的词元进行评分，选择使得训练数据似然性增加最多的词元对合并

Unigram 分词

- 从语料库中一组足够大的字符串或词元初始集合开始，迭代的删除其中的词元，直到达到预期词表大小
- 删除的选择标准：选择删除后使得训练语料似然增加最大的词元

词元化 (分词)

分词器的选用

分词器需要无损重构

- 分词结果可以准确无误地还原为原始输入文本

分词器需要有高压缩率

在给定文本数据的情况下，经过分词处理的词元数量应该尽量少

压缩比 = UTF-8字节数

词元化 (分词)

分词器的选用

- 1.分词器需要无损重构：分词结果可以准确无误地还原为原始输入文本
- 2.分词器需要有高压缩率：在给定文本数据的情况下，经过分词处理的词元数量应该尽量少
- 3.针对特殊领域需要针对性设计分词器，具体原因如下：
 - 英文语言模型使用中文语料预训练时通常需要扩词表
 - 数字的分词很重要

四种不同的分词器设计：（a）GPT-2 使用的未经处理的 BPE 分词器、（b）Llama-2 使用的单数位分词器($k=1$)、（c）Llama-3 和 GPT-3.5($k=3$)、GPT-4 使用的 3 数位贪心分词器，以及（d）改进对齐后的3 数位分词器。其中，（b）-（d）为贪心式分词器，其机制是对于预设的最大长度 k ，从左到右（（d）改为从右向左）依次截取 k 个数字组成一个 token，直至遇到非数字字符为止。

(a) 31415.926535897932


(b) 31415.926535897932

(c) 31415.926535897932

(d) 31415.926535897932

数据配比

整体需要多少训练数据？



$$L(N) = \left(\frac{N_c}{N}\right)^{\alpha_N}, \quad \alpha_N \sim 0.076, N_c \sim 8.8 \times 10^{13}$$
$$L(D) = \left(\frac{D_c}{D}\right)^{\alpha_D}, \quad \alpha_D \sim 0.095, D_c \sim 5.4 \times 10^{13}$$
$$L(C) = \left(\frac{C_c}{C}\right)^{\alpha_C}, \quad \alpha_C \sim 0.050, C_c \sim 3.1 \times 10^8$$

数据规模和参数规模同比例增加，倾向于多增加模型参数

KM scaling law

N: 模型规模, D: 数据规模, C: 计算算力, N_c : 嵌入参数数量, D_c : 训练数据数量, C_c : 总计算量
 $L(.)$ 表示交叉熵损失

绝大部分主流模型都使用了10T 以上的词元

DeepSeek-V3(14.8T), Qwen2.5(最多达到了18T)

Table 1 | **Current LLMs**. We show five of the current largest dense transformer models, their size, and the number of training tokens. Other than LaMDA (Thoppilan et al., 2022), most models are trained for approximately 300 billion tokens. We introduce *Chinchilla*, a substantially smaller model, trained for much longer than 300B tokens.

Model	Size (# Parameters)	Training Tokens
LaMDA (Thoppilan et al., 2022)	137 Billion	168 Billion
GPT-3 (Brown et al., 2020)	175 Billion	300 Billion
Jurassic (Lieber et al., 2021)	178 Billion	300 Billion
Gopher (Rae et al., 2021)	280 Billion	300 Billion
MT-NLG 530B (Smith et al., 2022)	530 Billion	270 Billion
<i>Chinchilla</i>	70 Billion	1.4 Trillion

与 KM law相似，但是建议多分配算力给数据，原始论文给出了大概 20:1 的一个分配

Chinchilla scaling law

数据配比

整体指导策略

1. 增加数据多样性

增加数据源异质性有利于改善模型综合表现

2. 优化数据混合

通过可学习的方式来优化数据组成


根据目标任务选择特征空间相似的预训练数据，或对下游任务性能产生正面影响的数据

3. 优化特定能力

通过增加特定数据源的比例来增强对应能力

数据配比

部分参考配比



类型	比例
通用	50%
数学&推理	25%
代码	17%
多语	8%


Llama 3数据配比

数据配比

自动化配比方法

DoReMi

1. 通过一个小型代理模型来确定最优的领域权重
2. 使用优化后的领域权重重新采样数据集，并训练一个大型模型




数据配比

自动化配比方法

数据配比定律

1. 基本思想：基本思想：预测不同数据混合比例下的模型性能，从而在实际训练之前找到最优的混合比例，提高模型性能并降低训练成本。


$$L_i(r_{1...M}) = c_i + k_i \exp \left(\sum_{j=1}^M t_{ij} r_j \right),$$



数据配比

自动化配比方法

数据配比定律




Domains	Default Mixture	Optimized Mixture
CommonCrawl	0.6700	0.1250
C4	0.1500	0.2500
Github	0.0450	0.1406
ArXiv	0.0450	0.2500
Books	0.0450	0.0938
StackExchange	0.0250	0.1250
Wikipedia	0.0200	0.0156

通过优化混合比例，1B模型在100B tokens的训练下达到了与默认混合比例训练148% tokens相当的性能。

数据课程

定义：按照**特定的顺序**或者分布安排预训练数据进行训练

基于专门构建的评测基准监控大语言模型的关键能力的学习过程，然后在预训练期间动态调整数据的混合配比。



数据课程

示例

模型	数据课程
CodeLLaMA (代码化)	2T通用词元→500B代码密集型词元
CodeLLaMA-Python (Python化)	2T通用词元→500B代码相关词元→100BPython代码相关词元
Llemma (数学化)	2T通用词元→500B代码相关词元→50~200B数学相关词元
CodeLLaMA (上下文扩展)	2.5T词元，4K上下文窗口→20B词元，16K上下文窗口

数据课程

预训练数据的动态批次配比

Algorithm 1: Dynamic Batch Loading

Require: Training data of k domains $D_1, D_2, \dots, D_k$, validation data $D_1^{\text{val}}, D_2^{\text{val}}, \dots, D_k^{\text{val}}$, initial data loading weights $w_0 \in \mathbb{R}^k$, reference loss $\ell_{\text{ref}} \in \mathbb{R}^k$, LM loss $\mathcal{L}$ or pruning loss $\mathcal{L}_{\text{prune}}$, training steps T , evaluation per m steps, model parameters θ (θ, z, ϕ, λ for pruning)

```
for  $t = 1, \dots, T$  do
  if  $t \bmod m = 0$  then
     $\ell_t[i] \leftarrow \mathcal{L}(\theta, z, D_i^{\text{val}})$  if pruning else  $\mathcal{L}(\theta, D_i^{\text{val}})$ 
     $\Delta_t[i] \leftarrow \max\{\ell_t[i] - \ell_{\text{ref}}[i], 0\}$   $\triangleright$  Calculate loss difference
     $w_t \leftarrow \text{UpdateWeight}(w_{t-m}, \Delta_t)$   $\triangleright$  Update data loading proportion
  end
  Sample a batch of data  $\mathcal{B}$  from  $D_1, D_2, \dots, D_k$  with proportion  $w_t$ ;
  if pruning then
    Update  $\theta, z, \phi, \lambda$  with  $\mathcal{L}_{\text{prune}}(\theta, z, \phi, \lambda)$  on  $\mathcal{B}$ 
  else
    Update  $\theta$  with  $\mathcal{L}(\theta, \mathcal{B})$ 
  end
end
```

Subroutine $\text{UpdateWeight}(w, \Delta)$

```
 $\alpha \leftarrow w \cdot \exp(\Delta)$   $\triangleright$  Calculate the unnormalized weights
 $w \leftarrow \frac{\alpha}{\sum_i \alpha[i]}$   $\triangleright$  Renormalize the data loading proportion
return  $w$ 
```

与DoReMi较为相似，逐批次地优化模型的训练数据配比



Figure 6: Left: Data weight of each batch during the continued pre-training stage. Right: Cumulative data usage for each domain.

训练配比随Batch优化逐步改变
对于配比优化的粒度更细

03

训练优化

2025


优化参数设置

模型	批次大小	学习率 (预热 → 峰值 → 衰减)	优化器	精度 类型	权重 衰减	梯度 裁剪
GPT-3	32K → 3.2M	预热 → 6×10^{-5} → 余弦	Adam	FP16	0.1	1.0
OPT	2M	预热 → 1.2×10^{-4} → 手动	AdamW	FP16	0.1	-
PaLM	1M → 4M	1×10^{-2} → 平方根倒数	Adafactor	BF16	lr^2	1.0
BLOOM	4M	预热 → 6×10^{-5} → 余弦	Adam	BF16	0.1	1.0
LLaMA-2	4M	预热 → 1.5×10^{-4} → 余弦	AdamW	-	0.1	1.0
Baichuan-2	-	预热 → 1.5×10^{-4} → 余弦	AdamW	BF16	0.1	0.5
Qwen-1.5	4M	预热 → 3×10^{-4} → 余弦	AdamW	BF16	0.1	1.0
InternLM-2	5M	预热 → 3×10^{-4} → 余弦	AdamW	-	0.1	-
Falcon	预热 → 4M	预热 → 1.25×10^{-4} → 余弦	AdamW	BF16	0.1	0.4
DeepSeek	18M	预热 → 3.2×10^{-4} → 余弦	AdamW	BF16	0.1	1.0
YuLan	4.5M	预热 → 3×10^{-4} → 余弦	Adam	BF16	0.1	1.0
GLM-130B	0.4M → 8.25M	预热 → 8×10^{-5} → 余弦	AdamW	FP16	0.1	1.0

动态批次调整：在训练过程中逐渐增加批次大小，最终达到百万级别

学习率预热与衰减：学习率将从一个非常小的数值线性平稳增加，直到达到预设的最大阈值，然后衰减到其最大阈值的10%。


学习率调整



学习率线性衰减、余弦衰减和平方根倒数衰减示意图


3D并行训练

数据并行



将模型复制、数据平均分配
分别计算后合并梯度，统一更新

零冗余优化器 (ZeRO)




将模型均分到不同卡，缓解冗余
计算时动态从对应卡读取参数

划线部分不长期存储
需要时动态获取

3D并行训练


张量并行



将模型参数 w 拆分为 w_1 和 w_2

在两张卡并行计算 xw_i 后拼接得到输出


流水线并行



将连续的层分配到不同卡

依次经过每卡串行计算

需要与梯度累积联合使用，
以达到流水线效果



多批次数据


GPipe: Efficient Training of Giant Neural Networks
using Pipeline Parallelism, NeurIPS 2024

▶ 3D并行训练

- 激活值是前向传播的结果，需要在反向传播时参与梯度计算

前向传播（激活值）


反向传播（梯度）



- 保存激活值需要占用大量显存

前向传播（激活值）


反向传播（梯度）



- 激活重计算：保留部分激活值，反向传播时重新计算其他激活值

混合精度训练

- 同时使用 32 位浮点数和 16 位浮点数计算
- 显存减半、效率翻倍
- DeepSeek-V3使用 FP8 混合训练，进一步减少密集型计算开销



04


预训练规律

2025

扩展定律

➤ 什么是扩展定律

- 通过扩展参数规模、数据规模和计算算力，大语言模型的能力会出现显著提升
- 扩展定律在本次大模型浪潮中起到了重要作用



扩展定律


➤ KM扩展定律

- OpenAI 团队建立了神经语言模型性能与参数规模 (N)、数据规模 (D) 和计算算力 (C) 之间的幂律关系。

$$L(N) = \left(\frac{N_c}{N} \right)^{\alpha_N}, \quad \alpha_N \sim 0.076, N_c \sim 8.8 \times 10^{13}$$

$$L(D) = \left(\frac{D_c}{D} \right)^{\alpha_D}, \quad \alpha_D \sim 0.095, D_c \sim 5.4 \times 10^{13}$$

$$L(C) = \left(\frac{C_c}{C} \right)^{\alpha_C}, \quad \alpha_C \sim 0.050, C_c \sim 3.1 \times 10^8$$



N_c : 嵌入参数数量, D_c : 训练数据数量, C_c : 总计算量, $L(.)$ 表示交叉熵损失。


扩展定律

➤ Chinchilla扩展定律

- DeepMind 团队于 2022 年提出了另一种形式的扩展定律,旨在指导大语言模型充分利用给定的算力资源优化训练

$$L(N, D) = E + \frac{A}{N^\alpha} + \frac{B}{D^\beta},$$


$$N_{\text{opt}}(C) = G \left(\frac{C}{6} \right)^a, \quad D_{\text{opt}}(C) = G^{-1} \left(\frac{C}{6} \right)^b,$$



▶ 涌现能力


➤ 什么是涌现能力

- 原始论文定义：“在小型模型中不存在、但在大模型中出现的能力”
- 模型扩展到一定规模时，特定任务性能突然出现显著跃升趋势，远超随机水平



涌现能力

- 涌现能力可能部分归因于评测设置
 - 本课程定义其为“**代表性能力**”，并不区分是否在小模型中存在



涌现能力

➤ 代表性能力

➤ 上下文学习 (In-context Learning)

- 在提示中为语言模型提供自然语言指令和任务示例，无需显式梯度更新就能为测试样本生成预期输出


$N \times$

Answer the following mathematical reasoning questions:

Q: If you have 12 candies and you give 4 candies to your friend, how many candies do you have left?
A: The answer is 8.

Q: If a rectangle has a length of 6 cm and a width of 3 cm, what is the perimeter of the rectangle?
A: The answer is 18cm.

Q: Sam has 12 marbles. He gives 1/4 of them to his sister. How many marbles does Sam have left?




涌现能力

➤ 代表性能力

➤ 逐步推理 (Step-by-step Reasoning)

- 在提示中引入任务相关的中间推理步骤来加强复杂任务的求解，从而获得更可靠的答案




▶ 涌现能力

➤ 涌现能力与扩展定律的关系

➤ 涌现能力和扩展定律是两种描述规模效应的度量方法

Scaling law describes a *predictable* increase pattern, but with *diminishing return*

可以理解为是一种
较为平滑的多任务
损失平均 (LM loss)



Model scaling is the key to the emergence of strong abilities

Emergent abilities transcend the scaling law, making the increase *unpredictable but profitable*

非平滑的、某种特定能力或任务的性能跃升 (Task loss)

05

总结与展望

2025

2025

谢谢大家

时间：202X.X