


智能识别系统设计

上课地点：南区计算机大楼323

深圳大学
计算机与软件学院



● 本次课程任务

1. 机器学习概述
2. 数据相关的问题
3. 机器学习研究内容
4. 机器学习基本概念
5. 机器学习常用算法


<https://www.gbitai.com/2019/10/8106.html>

● 机器学习概述

谷歌造出AI调香师：看一眼分子结构，就知道它闻起来什么味儿

图像、语言、声音、游戏，一直是AI界最喜欢“调戏”的几个目标。不过现在，谷歌把手伸向了一个不同的领域——气味。


把一个物质的分子结构，经过两轮神经网络的处理，就能把知道这种东西闻起来是玫瑰的芬芳，还是烤肉的香气。这就是一个AI调香师嘛！



● 机器学习概述

简单几笔素描就能“复原”真实人脸，这是沈向洋高徒出品的CSAGAN


看着这样一张抽象的人脸素描，你能猜出真人长什么样吗？
现在，有一只GAN，不仅能够完美突破次元壁，复现真实人脸：




<https://www.qbitai.com/2019/10/8221.html>

● 机器学习概述

人数统计系统搭建:



● 机器学习概述



机器学习概述

中国移动 上午 12:44 75%

交易记录

在途交易 历史交易

类型 ▾	状态 ▾	时间 ▾
分红		2018-06-28 00:00:00
中银慧投11号 分红		
分红		景顺长城优选混合基金 98.38 成功
买入		2018-05-15 16:19:00
中银慧投11号 成功		
申购		添富移动互联 1,057.00 成功
申购		嘉实新消费股票 1,289.00 成功
申购		博时黄金ETF联接C 1,017.00 成功
申购		富国天利增长债券 1,956.00 成功
申购		易基医疗行业 954.00 成功
申购		国投瑞银强债A类 1,884.00 成功
申购		景顺长城优选混合基金 1,315.00 成功
申购		华夏货币A 528.00 成功

中国移动 上午 12:44 75%


交易记录

在途交易 历史交易

类型 ▾	状态 ▾	时间 ▾
中银慧投11号 成功		
赎回		添富移动互联 696.20 成功
赎回		嘉实新消费股票 179.90 成功
赎回		博时黄金ETF联接C 158.52 成功
赎回		富国天利增长债券 428.47 成功
赎回		易基医疗行业 779.80 成功
赎回		国投瑞银强债A类 484.21 成功
转出		华夏货币A 60.50 成功
转出		景顺长城优选混合基金 910.67 成功
申购		华夏经济转型 1,499.68 成功
申购		广发中证基建工程指数 896.51 成功
申购		景顺长城量化新动力 330.91 成功
转入		华夏经济转型 59.72 成功
转入		景顺长城量化新动力 907.03 成功

● 机器学习概述

金融决策



数据分析与学习

国内环境


{ 板块热点
国家政策
个股分析
资产配置

外围环境

{ 国际市场
国际关系
国际事件

● 机器学习概述


- 机器学习(Machine Learning): 致力于研究如何通过计算的手段, 利用经验来改善系统自身的性能-- (周志华-机器学习)



形式定义: 假设用P来评估计算机程序在某任务类T上的性能, 若一个程序通过利用经验E在T中任务上获得了性能改善, 则程序对E进行了**学习**

经验: 数据驱动, 概率、统计和优化方法

学习算法: 从数据中产生“模型”的算法



● 机器学习概述

推理期

20世纪50~70年代

- 问题求解
- 定理证明

知识期

20世纪70年代

- 专家系统
- 知识工程

学习期

20世纪80年代


- 感知机
- 归纳学习
- 统计学习

- 1949年神经科学家赫步(Hebb)提出了机器学习的概念
- 1952年塞缪尔(Samuel) 使用”Machine Learning”名词
- 1980年卡内基梅隆大学举行第一届机器学习会议ICML
- 1986年Machine Learning创刊

主要学派：符号学派、联结学派、进化学派、贝叶斯学派、类推学派-佩德罗.多明戈斯《终极算法》

● 数据相关的问题

市县	签约套数 (套)	签约面积 (m ²)	签约住宅均 价(元/m ²)	签约非住宅 均价(元/m ²)	签约金额(元)
三亚	54	4323.43	18278.46	—	79025642.32
海口	130	10020.11	6729.2	9331.16	67427324.21
文昌	20	1166.28	7754.35	10179.27	9043743.318
琼海	5	417.5	5144.3	—	2147745.25
万宁	1	41.25	7102.01	—	292957.9125
陵水	5	552.68	24172.3	—	13359546.76
定安	1	102.82	4454.39	—	458000.3798
琼中	2	168.36	3500	—	589260
五指山	8	467.66	5859.42	—	2740216.357
临高	8	1605.42	4323.57	—	6941145.749
澄迈	97	7220.68	5068.46	8438.58	36597727.75
白沙	1	56.88	4380.91	—	249186.1608
儋州	35	2132.41	5580.29	6637.31	11899466.2
乐东	9	510.71	5400.97	—	2758329.389
总计	376	28786.19	8112.58	—	233530291.8



图源于网络

● 数据相关的问题



银行监控环境与模拟环境中的机器学习

● 数据相关的问题

■ 数据集(Data set)-医疗数据

样本集

ID	Age	Size	Nodes	Breast	Irradiated	...	Outcome
1	42	20-24	3-5	right	yes	...	recurrence-events
2	35	35-39	0-2	left	no	...	recurrence-events
3	55	25-29	6-8	left	yes	...	recurrence-events
4	57	35-39	?	right	no	...	recurrence-events
5	56	15-19	0-2	right	no	...	no-recurrence-events
6	43	35-39	0-2	right	yes	...	no-recurrence-events
7	59	25-29	3-5	right	yes	...	no-recurrence-events
8	56	40-44	?	left	no	...	no-recurrence-events
...	...	...	...	...	...	...	...
286	58	25-29	0-2	right	no	...	no-recurrence-events

数据集: $D = \{x_1, x_2, \dots, x_m\}$

样本: 又称示例或对象, 用 x_i 表示, 其中 m 表示样本的数目

● 数据相关的问题

特征集或属性集

ID	Age	Size	Nodes	Breast	Irradiated	...	Outcome
1	42	20-24	3-5	right	yes	...	recurrence-events
2	35	35-39	0-2	left	no	...	recurrence-events
3	55	25-29	6-8	left	yes	...	recurrence-events
4	57	35-39	?	right	no	...	recurrence-events
5	56	15-19	0-2	right	no	...	no-recurrence-events
6	43	35-39	0-2	right	yes	...	no-recurrence-events
7	59	25-29	3-5	right	yes	...	no-recurrence-events
8	56	40-44	?	left	no	...	no-recurrence-events
...	...	...	...	...	...	...	...
286	58	25-29	0-2	right	no	...	no-recurrence-events

特征：描述样本的表现或性质 $x_i = \{x_{i1}, x_{i2}, \dots, x_{id}\}$, d 称为维数

特征类型：连续-离散, 条件特征-**决策特征 (标记)**, **样本表示：** $\{x_i, y_i\}$

标记：离散值 (**分类**), 连续值 (**回归**), 也可能无标记 (**聚类**)

● 数据相关的问题



- 机器学习任务
- 文本：文本分类、垃圾邮件检测；
- 语音：识别、合成、验证；
- 图像：分类、标注，人脸识别、字符识别，手写体识别；
- 游戏：下棋、对战
- 其它：医疗诊断、欺诈检测，网络入侵、机器人、生物制药

● 机器学习的研究内容




● 机器学习的研究内容

有监督学习

任务：给定一组带类别标记信息的数据，如何训练有效的模型对未知类别的数据进行预测（有师学习）

标记信息：离散型（分类），连续型（回归）



常见有监督算法：

线性回归

线性判别分析

朴素贝叶斯

决策树

支持向量机


神经网络

K近邻

● 机器学习的研究内容

无监督学习

任务：给定一组无类别信息的数据，如何训练模型推断出数据的一些内在结构信息（无师学习）



常见无监督算法：

k-means

Fuzzy k-means

DBSCAN

谱聚类

层次聚类

PCA





NMF

PageRank

● 机器学习的研究内容

半监督学习

任务：给定少量有类别信息和大量无类别信息的数据，如何训练模型进行预测或推断出数据的一些内在结构



常见半监督算法：

主动学习

协同学习

分歧模型

图模型

半监督SVM

半监督聚类


图源于网络

- 机器学习的研究内容


例：医学图像分类

问题：将每个医学图像分类有无疾病和无疾病（二分类问题）


数据：大量有标记的有疾病和无疾病图像



- 机器学习的研究内容





● 机器学习的基本概念



收集数据→数据集划分→维度约简(可选)→算法选择→模型训练→模型测试

- 机器学习的基本概念

假设空间



演绎与归纳：科学推理的两个基本手段

归纳学习：“从样例中学习”——特殊到一般的“泛化”
(generalization) 过程，机械学习

假设空间：多个与训练集一致的“假设” (hypothesis) 集合

奥卡姆剃刀 (Occam's razor)：若有多个假设与观察一致，
则选最简单的那个—假设也即模型

● 机器学习的基本概念

模型评估与选择

错误率(error rate): 分类错的样本数目占样本总数的比率; 相应地, 可定义精度(accuracy), 即精度=1-错误率

误差(error): 模型的预测输出与样本的真实输出之间的差异

训练误差(training error): 模型在训练集上的误差

泛化误差(generalization error): 模型在新样本上的误差

泛化误差小, 但预测样本未知, 实际只能使训练误差小




书上的例题我都背下来了, 这门课我可以
得高分






图源于网络

● 机器学习的基本概念

模型评估与选择



你是半吊子
吗？



GG



普遍规律，泛化性能强

图源于网络

- 机器学习的基本概念

模型评估与选择




图 2.1 过拟合、欠拟合的直观类比


普遍规律，泛化性能强

图源于周志华教材《机器学习》


● 机器学习的基本概念

模型评估与选择

测试误差近似
泛化误差



1) 留出法



- 机器学习的基本概念

模型评估与选择

2) 交叉验证法 (cross validation)




图 2.2 10 折交叉验证示意图

3) 验证集 (validation set) - 调参

图源于周志华教材《机器学习》

● 机器学习的基本概念

模型评估与选择

性能度量：衡量模型泛化能力的评价标准

1) 回归任务-均方误差 (mean squared error)

$$E(f; D) = \frac{1}{m} \sum_{i=1}^m (f(\mathbf{x}_i) - y_i)^2$$

2) 分类任务-错误率、精度

$$E(f; D) = \frac{1}{m} \sum_{i=1}^m \Pi(f(\mathbf{x}_i) \neq y_i) \quad acc(f; D) = 1 - E(f; D)$$

3) 聚类任务-DB指数

$$DBI = \frac{1}{k} \sum_{i=1}^k \max_{j \neq i} \left(\frac{\text{avg}(C_i) + \text{avg}(C_j)}{d_{\text{cen}}(\boldsymbol{\mu}_i, \boldsymbol{\mu}_j)} \right)$$

● 机器学习的基本概念

模型评估与选择

偏差与方差





图 2.9 泛化误差与偏差、方差的关系示意图



左图源于周志华教材《机器学习》

●机器学习常用算法-回归方法

对于线性系统 $y_{m \times 1} = A_{m \times n} x_{n \times 1}$, 其中 $n > m$

可以通过施加约束项 $\|x\|=1$, 求解上述线性系统问题。

●机器学习常用算法-回归方法

利用拉格朗日乘子法，上述问题可以转化为以下问题的求解：

$$\begin{aligned} L(x) &= \|y - Ax\|^2 + \lambda (\|x\|^2 - 1) \\ &= \text{Tr}((y - Ax)^T (y - Ax)) + \lambda (\text{Tr}(x^T x) - 1) \\ &= \text{Tr}((y^T - x^T A^T)(y - Ax)) + \lambda (\text{Tr}(x^T x) - 1) \\ &= \text{Tr}(y^T y - y^T Ax - x^T A^T y + x^T A^T Ax) + \lambda (\text{Tr}(x^T x) - 1) \\ &= \text{Tr}(y^T y) - \text{Tr}(y^T Ax) - \text{Tr}(x^T A^T y) + \text{Tr}(x^T A^T Ax) + \lambda \text{Tr}(x^T x) - \lambda \end{aligned}$$

$$\begin{aligned} \frac{\partial L}{\partial x} &= -(y^T A)^T - (A^T y) + (A^T A + (A^T A)^T)x + \lambda \cdot 2x \\ &= -2A^T y + 2A^T Ax + 2\lambda x \end{aligned}$$

$$A^T y = (A^T A + \lambda I)x$$


$$x_{n \times 1} = (A_{m \times n}^T A_{m \times n} + \lambda I_{n \times n})^{-1} A_{m \times n}^T y_{m \times 1}$$

- 机器学习常用算法-聚类算法

算法：K-均值聚类

```
1 begin initialize  $n, c, \mu_1, \mu_2, \dots, \mu_c$ 
2 Do 按照最近邻  $\mu_i$  分类  $n$  个样本
3     重新计算  $\mu_i$ 
4 until  $\mu_i$  不再改变
5 Return  $\mu_1, \mu_2, \dots, \mu_c$ 
6 end
```

●机器学习常用算法-聚类算法




●机器学习常用算法-模糊c均值聚类

k -均值聚类的不足：算法要求每个样本数据点在一次迭代过程中只能被划分到**某个特定的簇**中。然而，在很多实际应用中样本数据并非都满足这种**非此即彼**的刚性划分，可能会存在一个样本同时隶属于多个类别的情形。为使聚类算法能够较好地适应此类应用场景，人们使用模糊数学理论对传统聚类算法进行改进。

例如问题：对汉字结构进行聚类，“样”，“洋”，“林”

●机器学习常用算法-模糊c均值聚类

模糊c-均值聚类算法的基本思想：与k-均值聚类算法较为类似，使用模糊数学中属于 $[0, 1]$ 区间的隶属度指标度量单个样本隶属于各个簇的程度，并规定每个样本到所有簇的隶属度之和均为1，若某个样本到某个簇的隶属度为1，则表示该样本完全隶属于该簇。



$$\alpha_1 + \alpha_2 + \alpha_3 = 1$$

●机器学习常用算法-模糊c均值聚类

给定示例样本数据集 $D = \{X_1, X_2, \dots, X_n\}$, 假设对数据集 D 进行模糊聚类得到 c 个簇 $C_1, C_2, \dots, C_c$, D 中任意给定单个样本 X_i 对于第 j 个簇 C_j 的隶属度为 α_{ij} , 则可使用如下加权欧式距离 w_{ij} 度量样本 X_i 与簇 C_j 之间的相关性:

$$w_{ij} = \alpha_{ij} \left(\sum_{t=1}^m (x_{it} - u_{jt})^2 \right)^{1/2}$$

其中 u_{jt} 表示第 j 个簇 C_j 的聚类中心 U_j 第 t 个坐标分量。

●机器学习常用算法-模糊c均值聚类

依据上述加权欧式距离 w_{ij} 计算公式可得所有簇内加权距离之和为：

$$d(\alpha_{ij}) = \sum_{j=1}^c \sum_{i=1}^n \alpha_{ij} \left(\sum_{t=1}^m (x_{it} - u_{jt})^2 \right)^{1/2}$$

为控制隶属度对聚类最终效果的影响并简化计算，可将上述加权距离之和 $d(\alpha_{ij})$ 改写为如下形式：

$$J(\alpha_{ij}) = \sum_{j=1}^c \sum_{i=1}^n \alpha_{ij}^p \sum_{t=1}^m (x_{it} - u_{jt})^2$$

其中 p 为控制隶属度影响的参数，通常取 $p = 2$ 。 p 值越大，则隶属度对最终的聚类效果影响就越大。

 ●机器学习常用算法-模糊c均值聚类

上述关于 α_{ij} 的函数 $J(\alpha_{ij})$ 既包含所有簇内加权总距离，又包含该聚类算法边界划分的模糊程度，故可将其作为目标函数将样本数据集 D 的模糊聚类问题转化为 $J(\alpha_{ij})$ 的最小值优化问题，即：

$$\arg_{\alpha_{ij}} \min J(\alpha_{ij}); \text{ s. t. } \sum_{j=1}^c \alpha_{ij} = 1$$

可用拉格朗日乘数法求解上述条件优化问题。令拉格朗日函数为：

$$\hat{J}(\alpha_{ij}) = \sum_{j=1}^c \sum_{i=1}^n \alpha_{ij}^p \sum_{t=1}^m (x_{it} - u_{jt})^2 + \sum_{i=1}^n \lambda_i \left(\sum_{j=1}^c \alpha_{ij} - 1 \right)$$

●机器学习常用算法-模糊c均值聚类

分别令 $\hat{J}(\alpha_{ij})$ 对 α_{ij} 的偏导数令为0，则有：

$$\frac{\partial \hat{J}}{\partial \alpha_{ij}} = p \alpha_{ij}^{p-1} \sum_{t=1}^m (x_{it} - u_{jt})^2 + \lambda_i = 0$$

解得： $\alpha_{ij} = \left[\frac{-\lambda_i}{p \sum_{t=1}^m (x_{it} - u_{jt})^2} \right]^{\frac{1}{p-1}}$

结合隶属度约束条件可消去未知参数 λ_i ，得到隶属度 α_{ij} 的计算公式：

$$\alpha_{ij} = \frac{\left[\frac{1}{\sum_{t=1}^m (x_{it} - u_{jt})^2} \right]^{\frac{1}{p-1}}}{\sum_{k=1}^c \left[\frac{1}{\sum_{t=1}^m (x_{it} - u_{kt})^2} \right]^{\frac{1}{p-1}}}$$

式表明第 i 个样本到第 j 个簇的最佳隶属度 α_{ij} 取决于该样本点到第 j 个簇心的距离的倒数与其到所有簇心距离倒数之和。

●机器学习常用算法-模糊c均值聚类

如何消去 λ_i 获得 α_{ij} ?

$$\begin{cases} \alpha_{ij} = \left[\frac{-\lambda_i}{p \sum_{t=1}^m (x_{it} - u_{jt})^2} \right]^{\frac{1}{p-1}} \\ \sum_{j=1}^c \alpha_{ij} = 1 \end{cases}$$

$$\alpha_{ij} = \left(\frac{-\lambda_i}{p} \right)^{\frac{1}{p-1}} \left[\frac{1}{\sum_{t=1}^m (x_{it} - u_{jt})^2} \right]^{\frac{1}{p-1}}$$

代入约束条件得：

$$\sum_{j=1}^c \alpha_{ij} = \sum_{j=1}^c \left(\frac{-\lambda_i}{p} \right)^{\frac{1}{p-1}} \left[\frac{1}{\sum_{t=1}^m (x_{it} - u_{jt})^2} \right]^{\frac{1}{p-1}} = \left(\frac{-\lambda_i}{p} \right)^{\frac{1}{p-1}} \sum_{j=1}^c \left[\frac{1}{\sum_{t=1}^m (x_{it} - u_{jt})^2} \right]^{\frac{1}{p-1}} = 1$$

●机器学习常用算法-模糊c均值聚类

$$\left(\frac{-\lambda_i}{p}\right)^{\frac{1}{p-1}} = \frac{1}{\sum_{j=1}^c \left[\frac{1}{\sum_{t=1}^m (x_{it} - u_{jt})^2} \right]^{\frac{1}{p-1}}}$$

代入以下公式

$$\alpha_{ij} = \left(\frac{-\lambda_i}{p}\right)^{\frac{1}{p-1}} \left[\frac{1}{\sum_{t=1}^m (x_{it} - u_{jt})^2} \right]^{\frac{1}{p-1}}$$

可以得到:

$$\alpha_{ij} = \frac{1}{\sum_{j=1}^c \left[\frac{1}{\sum_{t=1}^m (x_{it} - u_{jt})^2} \right]^{\frac{1}{p-1}}} \cdot \left[\frac{1}{\sum_{t=1}^m (x_{it} - u_{jt})^2} \right]^{\frac{1}{p-1}} = \frac{\left[\frac{1}{\sum_{t=1}^m (x_{it} - u_{jt})^2} \right]^{\frac{1}{p-1}}}{\sum_{j=1}^c \left[\frac{1}{\sum_{t=1}^m (x_{it} - u_{jt})^2} \right]^{\frac{1}{p-1}}}$$

●机器学习常用算法-模糊c均值聚类

还可以将目标函数 $\hat{J}(\alpha_{ij})$ 看成是聚类中心 u_{jt} 的函数，即 $\hat{J}(u_{jt})$ ，并由此通过对目标函数 $\hat{J}(u_{jt})$ 作最小值优化计算进一步得到各簇最优聚类中心坐标 U_j 。为此，分别令 $\hat{J}(u_{jt})$ 关于 u_{jt} 的偏导数为0，可得到如下方程：

$$-2 \sum_{i=1}^n \alpha_{ij}^p (x_{it} - u_{jt}) = 0$$

即有： $\sum_{i=1}^n \alpha_{ij}^p x_{it} = \sum_{i=1}^n \alpha_{ij}^p u_{jt}$ ， $t = 1, 2, \dots, m$

由此可得如下聚类中心计算公式：

$$U_j = \frac{\sum_{i=1}^n \alpha_{ij}^p X_i}{\sum_{i=1}^n \alpha_{ij}^p}$$

- 机器学习常用算法-模糊c均值聚类

模糊c-均值聚类算法依据上述隶属度和聚类中心计算公式，算法具体步骤如下：

（1）设定簇的数目 c 和阈值 ε ，并令 $s = 0$ 。随机初始化所有样本对所有簇的隶属度，并将其记录在隶属度矩阵 Q 中，即：

$$Q^0 = \begin{pmatrix} \alpha_{11} & \dots & \alpha_{1c} \\ \dots & \dots & \dots \\ \alpha_{n1} & \dots & \alpha_{nc} \end{pmatrix}$$

其中元素 α_{ij} 为非负实数且满足隶属度约束条件 $\sum_{j=1}^c \alpha_{ij} = 1$ ；

- 机器学习常用算法-模糊c均值聚类

(2) 使用隶属度矩阵 Q 计算各簇的聚类中心 $u_j^q, j = 1, 2, \dots, c$, 计算目标函数值 J^t ;

(3) 若 $J^s \geq \varepsilon$ 或 $|J^s - J^{s-1}| \geq \varepsilon$, 则依据下式更新隶属度矩阵 Q , 令 $s = s + 1$ 并返回步骤2; 否则, 依据隶属度矩阵 Q^s 得到聚类结果并结束算法。

$$\alpha_{ij} = \frac{\left[\frac{1}{\sum_{t=1}^m (x_{it} - u_{jt})^2} \right]^{\frac{1}{p-1}}}{\sum_{k=1}^c \left[\frac{1}{\sum_{t=1}^m (x_{it} - u_{kt})^2} \right]^{\frac{1}{p-1}}}$$

 ●机器学习常用算法-模糊c均值聚类

【例题】 现假设在二维平面中有6个点，如下表所示,试使用模糊 c -均值聚类算法对数据集进行模糊二均值聚类，当每个聚类中心相邻两次迭代的变化均小于 10^{-4} 时停止聚类过程并算出相应的聚类中心和隶属度矩阵结果。


	X_1	X_2	X_3	X_4	X_5	X_6
x_{i1}	3	4	9	14	18	21
x_{i2}	3	10	6	8	11	7

●机器学习常用算法-模糊c均值聚类

【解】将表中数据点二维空间分布情况如下图所示。取 $p = 2$ ，并令：

$$d_{ij} = \left(\sum_{t=1}^m (x_{it} - u_{jt})^2 \right)^{\frac{1}{2}}, \quad d_{ik} = \left(\sum_{t=1}^m (x_{it} - u_{kt})^2 \right)^{\frac{1}{2}}$$

依据隶属度公式进行计算。



$$\alpha_{ij} = \frac{\left[\frac{1}{\sum_{t=1}^m (x_{it} - u_{jt})^2} \right]^{\frac{1}{p-1}}}{\sum_{k=1}^c \left[\frac{1}{\sum_{t=1}^m (x_{it} - u_{kt})^2} \right]^{\frac{1}{p-1}}}$$

 ●机器学习常用算法-模糊c均值聚类

随机选择的初始聚类中心分别为 $c_1 = a, c_2 = b$ ，使用该聚类中心确定第一次划分：

对于任意点 X_i ，使用 α_{ij} 计算公式计算隶属度：对于点 X_1 ，由于其为第一个簇 C_1 的聚类中心，故有 $\alpha_{11} = 1$ ， $\alpha_{12} = 0$ ，同理，对于点 X_2 ，有 $\alpha_{21} = 0$ ， $\alpha_{22} = 1$ 。对于点 X_3 ，将数据带入隶属度公式计算，得到 $\alpha_{31} = 0.48, \alpha_{32} = 0.52$ 。同理计算得其他数据点对应的隶属度，根据隶属度数据将聚类中心更新为：

$$c'_j = \left(\frac{\sum_i \alpha_{ij}^2 x_{i1}}{\sum_i \alpha_{ij}^2}, \frac{\sum_i \alpha_{ij}^2 x_{i2}}{\sum_i \alpha_{ij}^2} \right)$$

- 机器学习常用算法-模糊c均值聚类

带入数据可得第一次迭代时的聚类中心为:

$$c'_1 = (8.47, 5.12), \quad c'_2 = (10.42, 8.99)$$

隶属度矩阵为:

$$M_1^T = \begin{bmatrix} 1 & 0 & 0.48 & 0.42 & 0.41 & 0.47 \\ 0 & 1 & 0.52 & 0.58 & 0.59 & 0.53 \end{bmatrix}$$

迭代执行上述步骤可得第二次迭代时, 聚类中心为:

$$c'_1 = (8.51, 6.11), \quad c'_2 = (14.42, 8.69)$$

隶属度矩阵为:

$$M_2^T = \begin{bmatrix} 0.73 & 0.49 & 0.91 & 0.26 & 0.33 & 0.42 \\ 0.27 & 0.51 & 0.09 & 0.74 & 0.67 & 0.58 \end{bmatrix}$$

- 机器学习常用算法-模糊c均值聚类

第三次迭代时的聚类中心为:

$$c'_1 = (6.40, 6.24), \quad c'_2 = (16.55, 8.64)$$

隶属度矩阵为:

$$M_3^T = \begin{bmatrix} 0.80 & 0.76 & 0.99 & 0.02 & 0.14 & 0.23 \\ 0.20 & 0.24 & 0.01 & 0.98 & 0.86 & 0.77 \end{bmatrix}$$


重复上述过程, 经过8次迭代得到如下聚类中心和隶属度矩阵:

$$c'_1 = (5.24, 6.34), \quad c'_2 = (17.84, 8.73)$$


$$M_8^T = \begin{bmatrix} 0.94 & 0.93 & 0.86 & 0.16 & 0.03 & 0.05 \\ 0.06 & 0.07 & 0.14 & 0.84 & 0.97 & 0.95 \end{bmatrix}$$

此时每个聚类中心相邻两次迭代的变化均小于 10^{-4} 。

●机器学习常用算法-感知器分类算法



线性可分



线性不可分

- 机器学习常用算法-感知器分类算法

感知机目标是找到一个线性可分的超平面：

$$w_1x_1 + w_2x_2 + \cdots + w_mx_m + b = 0$$

感知机

$$f(x) = \text{sign}(w^T x + b)$$

其中输入样本的空间 $X \subseteq \mathbb{R}^n$ ，输出样本空间 $Y = (+1, -1)$ ，

输入样本 $x \in X$ ，输出样本 $y \in Y$ ， w 和 b 是感知模型参数，

符号函数为

$$\text{sign}(x) = \begin{cases} +1, & x \geq 0 \\ -1, & x < 0 \end{cases}$$

- 机器学习常用算法-感知器分类算法

对于一个样本 x_1 , 若

$$w^T x_1 + b \geq 0$$

则被分为+1类

若

$$w^T x_1 + b < 0$$

则被分为-1类

- 机器学习常用算法-感知器分类算法

感知器模型损失函数

把满足 $w^T x_1 + b \geq 0$ 输出为+1, 满足 $w^T x_1 + b < 0$ 输出为-1。

因此正确分类样本满足 $y(w^T x + b) > 0$

错误分类样本满足 $y(w^T x + b) < 0$

- 机器学习常用算法-感知器分类算法

感知器模型损失函数

对于一个错分样本 x_i , 有 $y_i(w^T x_i + b) < 0$

该样本到超平面（分类面）的距离是：

$$y_i(w^T x_i + b) / \|w\|_2$$

$$\text{令 } \|w\|_2 = 1$$

所有错分点到超平面的距离之和为

$$-\sum_{x_i \in E} y_i(w^T x_i + b)$$

- 机器学习常用算法-感知器分类算法

感知器模型损失函数

最终的损失函数为

$$L(w, b) = - \sum_{x_i \in E} y_i (w^T x_i + b)$$

损失函数的梯度为

$$\nabla_w L(w, b) = - \sum_{x_i \in E} y_i x_i$$

$$\nabla_b L(w, b) = - \sum_{x_i \in E} y_i$$

- 机器学习常用算法-感知器分类算法

感知器参数更新

对于一个错误分类点, (x_i, y_i) 其对 w, b 的更新如下:

$$w \leftarrow w + \eta y_i x_i$$

$$b \leftarrow b + \eta y_i$$

通过参数更新, 不断调整分类面, 使损失函数不断减小, 最终使其对错误分类点, 能够正确分类。

●机器学习常用算法-感知器分类算法

批处理感知器算法

```
1 begin initialize  $w, \eta$ , 准则  $\theta$ ,  $k \leftarrow 0$   
2     do  $k \leftarrow k + 1$   
3          $w \leftarrow w + \eta(k) \sum_{y \in \Omega_k} y$   
4     until  $\left| \eta(k) \sum_{y \in \Omega_k} y \right| < \theta$   
5     return  $w$   
6 end
```


●机器学习常用算法-感知器分类算法

用感知器算法求解向量，训练样本为：

$$w_1 : \{(0, 0, 0)^T, (1, 0, 0)^T, (1, 0, 1)^T, (1, 1, 0)^T\}$$

$$w_2 : \{(0, 0, 1)^T, (0, 1, 1)^T, (0, 1, 0)^T, (1, 1, 1)^T\}$$

设 $w(0) = (-1, -2, -2, 0)^T$ 。请绘出区分界面示意图。



● 第二次试验报告

视频人脸检测及识别系统设计

实验报告内容：



- 1) 从视频或图像序列中创建训练样本，其中类别个数为**10**，每类样本有**10**个人脸图像；
- 2) 用**PCA**方法把训练样本投影到子空间，获得训练样本在子空间的投影以及投影矩阵，并存储到文本文件中，以便测试时调用；
- 3) 对**10**个类别的测试视频或测试图像序列进行测试，对于每一个类，输入其测试视频或测试图像序列，然后通过人脸检测、归一化、分类等一系列方法实现对视频或图像序列中人脸的识别，并统计识别率，若**10**个测试视频（或图像序列）都识别正确，则识别率为**100%**。

提交时间：2020年11月19日下午5:00

● 主成分分析算法实现详解

快速PCA算法原理

输入数据矩阵 X (维数 $d*n$)，其中 d 是样本维数， n 是样本个数

1. 求样本均值 m (维数 $d*1$)，即对 X 中所有样本求均值；
2. 计算中心化数据 $X_m(d*n)$ ，即 X 中的每一个样本都要减去均值 m ，形成的数据矩阵；
3. 计算 R 矩阵(维数 $n*n$)= $X_m' * X_m$ ，其中去中心化数据矩阵 X_m 维数是 $d*n$ ；
4. 对 R 矩阵进行特征分解，获得前 $NumAxes$ 个最大特征值，及对应特征向量，则可以获得特征向量矩阵 P （维数 $NumAxes*n$ ）；
5. 对特征向量矩阵 P （维数 $NumAxes*n$ ）左乘 $X_m(d*n)$ 得到 S 的特征向量 V (维数 $d*NumAxes$)，即 $V = X_m * P'$ ；
6. 对每一个特征向量，把他们归一化，即每个元素除以向量的2范数（所有获得的特征向量构成特征向量矩阵 V ，维数 $d*NumAxes$ ）；
7. 把去中心化的数据 X_m （维数 $d*n$ ），投影到特征向量矩阵 V （维数 $d*NumAxes$ ）获得低维表示 T (维数 $n*NumAxes$)= $X_m' * V$ 。

- 子空间方法-主成分分析基本原理

散布矩阵 $S=X_m X_m'$ 维数 $d*d$ ，当维数很高时，计算非常耗时

考虑 $R=X_m' X_m$ 维数 $n*n$ ，在识别问题中 n 远远小于 d


令 v 是 R 的特征向量

所以有
$$X_m^T X_m v = \lambda v$$

$$X_m X_m^T X_m v = \lambda X_m v$$

$$S(X_m v) = \lambda (X_m v)$$


也即 R 的特征向量左乘 X_m 即得到 S 的特征向量，但特征值分解计算量大大减小



● 主成分分析算法实现详解

快速PCA算法实现要注意的地方：

1. 输入部分：所有训练样本图像和测试样本图像都要归一化到统一的大小，再拉成列向量(维数 $d*1$)，数据矩阵 X (维数 $d*n$)的每一列就是由所有样本对应列向量构成；
2. 在第4步对散布矩阵进行特征分解后，要对特征值从大到小进行排序，对应特征向量的排序相应发生变化；对于特征值很小或者为0的特征向量可以忽略，也即最终选择特征向量的个数 $NumAxes \leq n$ ；
3. 低维表示 T (维数 $n*NumAxes$)中的每一行表示每一个样本（维数 $d*1$ ）在低维空间的表示 $t(1*NumAxes)$ ，在算法中最好把 T 和 t 都转置形成标准的向量表示格式。这样，原来 d 维的样本，在子空间中就变成 $NumAxes$ 维的向量，实现了降维和子空间表示的目的，其中 $NumAxes \leq n$ 。




● 分类框架的设计

基于快速PCA算法分类方法

已知：每一类别的训练样本，假设有C类，每一类有k个样本，共有 $n=C*k$ 个；并已知每一类的标签1,2,3...C。


1. 利用快速PCA算法先在训练样本上计算子空间的投影向量矩阵V(维数 $d*NumAxes$)，那么对于任意一个样本s(维数 $d*1$)，通过投影得到在子空间中的表示 $s'*V=u$ (维数 $1*NumAxes$)；同时获得训练样本在子空间的表示矩阵T(维数 $n*NumAxes$)；
2. 循环以下操作
3. 给定一个测试样本t1，计算它在子空间的投影u1；
4. 分类法1：采用最近邻分类方法，u1离哪个子空间中的训练样本最近，就划分到哪一类。根据分类结果与已知标签对比统计正确率。
5. 分类法2：计算子空间中每一类训练样本的均值，u1离哪一类的距离最近，就把它划分到哪一类。根据分类结果与已知标签对比统计正确率。
6. 结束循环

● 分类框架的设计



PCA投影

PCA投影



● 基于主成分分析的视频人脸识别程序设计

训练



人脸检测

1

图像归一化

2

投影

PCA子空间

3

特征存储到本地硬盘
测试时要加载特征

4

测试



人脸检测

图像归一化

投影矩阵


5

测试样本在子空间表示

6

分类

● 基于主成分分析的视频人脸识别程序设计




- 基于主成分分析的视频人脸识别程序设计

基本PCA测试数据

X	Y
0.01	0.68
0.33	0.74
0.16	0.45
0.79	0.08
0.31	0.22
0.52	0.91
0.16	0.15
0.6	0.82
0.26	0.53
0.65	0.9

meanvector =
0.379 0.548



- 基于主成分分析的视频人脸识别程序设计

去中心化后的数据

$X_m =$

-0.369	0.132
-0.049	0.192
-0.219	-0.098
0.411	-0.468
-0.069	-0.328
0.141	0.362
-0.219	-0.398
0.221	0.272
-0.119	-0.018
0.271	0.352

- 基于主成分分析的视频人脸识别程序设计

Eigenvalues =

0.901890466313468

0.540759533686533

Eigenvectors =

0.256342603861391

0.966585986576239

-0.966585986576239

0.256342603861391

- 基于主成分分析的视频人脸识别程序设计

快速PCA测试数据, $d=4$, $n=3$

```
x = [ 0.23  0.35  0.82  
      0.01  0.04  0.16  
      0.64  0.73  0.64  
      0.45  0.54  0.29];
```

```
%Eigenvectors: n*n  
rr=rank(R)  
if NumAxes>rr %  
    NumAxes=rr;  
end
```

```
meanvector =  
    0.4666666666666667  
        0.07  
        0.67  
    0.4266666666666667
```

● 基于主成分分析的视频人脸识别程序设计

$X_m =$

-0.236666666666667	-0.116666666666667	0.353333333333333
-0.06	-0.03	0.09
-0.03	0.0599999999999999	-0.03
0.0233333333333333	0.113333333333333	-0.136666666666667

$R =$

0.0610555555555555	0.0302555555555555	-0.0913111111111111
0.0302555555555555	0.0309555555555555	-0.0612111111111111
-0.0913111111111111	-0.0612111111111111	0.152522222222222

● 基于主成分分析的视频人脸识别程序设计

REigenvectors =

-0.489964510815981	0.653147337748172	0.577350269189625
-0.320659931496101	-0.750895382193539	0.577350269189627
0.810624442312081	0.09774804444537	0.577350269189626

DiagEigenvalues =

0.231926631000866	0	0
0	0.0126067023324677	0
0	0	-4.37832480216799e-17

● 基于主成分分析的视频人脸识别程序设计

对特征向量矩阵 P （维数 $\text{NumAxes} \times n$ ）左乘 $X_m(d \times n)$ 得到 S 的特征向量 V （维数 $d \times \text{NumAxes}$ ），即 $V = X_m * P'$;

$X_m =$

-0.2366666666666667	-0.1166666666666667	0.3533333333333333
-0.06	-0.03	0.09
-0.03	0.0599999999999999	-0.03
0.0233333333333333	0.1133333333333333	-0.1366666666666667

$P^T =$

-0.489964510815981	0.653147337748172
-0.320659931496101	-0.750895382193539
0.810624442312081	0.09774804444537

Eigenvectors =

0.439789229184596	-0.032436099640457
0.111973868401929	-0.00786465479900085
-0.0288593938346491	-0.0675805843974186
-0.158559304604582	-0.0832202715086777