

机器学习 Machine Learning

——机器学习简介


张书瑜

shuyu-zhang@szu.edu.cn

人工智能

AI value creation
by 2030

\$13
trillion




365种工作消失概率(前十名、后十名)

	职业种类	10-15年内被替代的可能性
1	人工智能科学家	0.1%
2	创业者	0.1%
3	心理学家	0.1%
4	宗教教职人员	0.1%
5	酒店与住宿经理或业主	0.1%
6	首席执行官	0.1%
7	首席营销官	0.1%
8	卫生服务与公共卫生管理或主管	0.1%
9	教育机构高级专家	0.1%
10	特殊教育教师	0.1%
356	纸料和木料机操作工	96.5%
357	装配工和常规程序操作工	96.7%
358	财务类行政人员	96.9%
359	银行或邮局职员	97.1%
360	簿记员、票据管理员或工资结算员	97.3%
361	流水线质检员	97.5%
362	常规程序检查员和测试员	97.7%
363	过秤员、评级员或分类员	97.9%
364	打字员或相关键盘工作者	98.1%
365	电话销售员/市场	98.3%

数据来源：牛津大学、麦肯锡、普华永道、创新工场研究报告综合

人工智能



人工智能

人工智能(Artificial Intelligence, AI) 是一种以智能**人类思维**的类似方式使计算机、计算机控制的机器人或软件智能地思考的方法。

人工智能的核心，是使计算机具有智能的根本途径，其应用遍及人工智能的各个领域，它主要使用归纳、综合而不是演绎。

人工智能是基于计算机科学，生物学，心理学，语言学，数学和工程学等学科的科学和技术。人工智能的主要推动力是开发与人类智能相关的计算机功能。

人工智能

自动驾驶

Can do



Cannot do



stop



hitchhiker



bike turn

人类的学习?

- **如何从完全“无知”到掌握知识?**

1. 婴儿的认知能力 (声音、人脸、汽车...)
2. 语言/颜色/形状等特征统计
3. 重要的二个特点: 容错性, 推广能力 (举一反三)

- **有监督学习**

月亮

- **无监督学习**

新闻分组



人类学习vs机器学习?


- **人类学习:**

1. 输入源可以是视觉、听觉、嗅觉、触觉、味觉等等;
2. 人类可以根据日常所见、所听进行推理与归纳, 比如过马路要等红绿灯、程序员秃顶的比较多。


- **机器学习:**

1. 输入数据必须是计算机可以处理的, e.g. 一系列数值;
2. 学习模式需要一些指导, 比如标注数据、人为设定loss或学习规则等

AI&ML&DL



机器学习



机器学习

- Tom Michael Mitchell, 1997
- 对于某给定的任务 T ，在合理的性能度量方案 P 的前提下，某计算机程序可以自主学习任务 T 的经验 E ；随着提供合适、优质、大量的经验 E ，该程序对于任务 T 的性能逐步提高。
- 这里最重要的是机器学习的对象：
 1. 任务Task, T ，一个或者多个
 2. 经验Experience, E
 3. 性能Performance, P即：随着任务的不断执行，经验的累积会带来计算机性能的提升。

机器学习

机器学习是人工智能的一个分支。机器学习主要是研究如何使计算机从给定的数据中学习规律，即从观测数据（样本）中寻找规律，并利用学习到的规律（模型）对未知或无法观测的数据进行预测。

针对经验 E (experience) 和一系列的任务 T (tasks) 和一定表现的衡量 P ，如果随之经验 E 的积累，针对定义好的任务 T 可以提高表现 P ，就说计算机具有学习能力。

机器学习

最早的机器学习应用-垃圾邮件分辨

传统的计算机解决问题思路：

- 编写规则，定义“垃圾邮件”，让计算机去执行
- 对于很多问题，规则很难定义
- 规则在不断变化




机器学习

图像识别



机器学习

人脸识别



30	32	22	12	10	10	12	33	35	30
12	11	12	234	170	176	13	15	12	12
234	222	220	230	200	222	230	234	56	78
190	220	186	112	110	110	112	180	30	32
49	250	250	250	4	2	254	200	44	6
55	250	250	250	3	1	250	245	25	3
189	195	199	150	110	110	182	190	199	55
200	202	218	222	203	200	200	208	215	222
219	215	220	220	222	214	215	210	220	220
220	220	220	220	221	220	221	220	220	222

机器学习

数字识别



机器学习

在机器学习中，通常我们解决问题的流程如下：

- (1) 搜集足够多的数据；
- (2) 通过分析问题本身或者分析数据，我们认为模型 f 是可以从数据中学习出来的；
- (3) 选择合适的模型和算法，从数据中学习出模型 f ；
- (4) 评价模型 f ，并将其利用在实际中处理新的数据

在实际中，还需要根据应用的实际情况及时更新模型 f 。例如，若数据发生了显著变化，则需要更新模型 f 。因此，在实际部署机器学习模型时，上面的第3步和第4步是一个循环反复的过程。

银行贷款

在现实生活中，向银行申请贷款是比较常见的，如房屋贷款、汽车贷款等。银行在办理个人贷款业务时，会根据申请人的经济情况来估计申请人的还款能力，并根据不同还款能力确定安全的借款金额和相应的条款（如不同的利率）。在美国，每个成年人都有相应的信用分数（credit score），用来衡量和评估借款者的还款能力和风险。

在估计申请者的还款能力时，需要搜集用户的多个方面的信息，包括：

- 收入情况；
- 年龄、性别；
- 职业；
- 家庭情况，如子女数量等；
- 还款历史，包括未按时还款的记录、还款金额等；
- 现有的各种贷款和欠款情况等。

机器学习

机器学习可以解决什么

给定数据的预测问题

- 数据清洗/特征选择
- 确定算法模型/参数优化
- 结果预测

不能解决什么

- 大数据存储/并行计算
- 做一个机器人

机器学习



what society thinks I
do




what my friends think
I do



what my parents think
I do

$$\begin{aligned} L_p &= \frac{1}{2} \|\mathbf{w}\|^2 - \sum_i \alpha_i y_i (\mathbf{x}_i \cdot \mathbf{w} + b) + \sum_i \alpha_i \\ \alpha_i &\geq 0, \forall i \\ \mathbf{w} &= \sum_i \alpha_i y_i \mathbf{x}_i, \sum_i \alpha_i y_i = 0 \\ \nabla \hat{g}(\theta_t) &= \frac{1}{n} \sum_{i=1}^n \nabla \ell(x_i, y_i; \theta_t) + \nabla r(\theta_t) \\ \theta_{t+1} &= \theta_t - \eta_t \nabla \ell(x_{i(t)}, y_{i(t)}; \theta_t) - \eta_t \cdot \nabla r(\theta_t) \\ \mathbb{E}_{i(t)}[\ell(x_{i(t)}, y_{i(t)}; \theta_t)] &= \frac{1}{n} \sum_i \ell(x_i, y_i; \theta_t). \end{aligned}$$

what other programmers
think I do



what I think I do

```
>>> from sklearn import svm
```

what I really do

机器学习研究意义

如果我们能发现有效的机器学习方法，利用它可以将观察数据（现象）转换为模型，这将一劳永逸的解决信息有效利用的难题！

- 网络数据
- 金融数据
- 生物数据
- 气象数据
- 地震观察数据
- 自然物体分类识别数据...

从而实现真正意义上的机器智能（电脑）

机器学习

阅读材料

- [Mitchell, 1997]是第一本机器学习专门教材.
- [Duda et al., 2001; Alpaydin, 2004; Flach, 2012]为出色的入门读物.
- [Hastie et al., 2009]为进阶读物, [Bishop, 2006]适合于贝叶斯学习偏好者.
- [Shalev-Shwartz and Ben-David, 2014]适合于理论偏好者.
- 《机器学习:一种人工智能途径》 [Michalski et al., 1983]汇集了20位学者撰写16篇文章, 是机器学习早期最重要的文献.
- [Dietterich, 1997] 对机器学习领域的发展进行了评述和展望。

机器学习

阅读材料

- 机器学习领域最重要的国际学术会议是国际机器学习会议(ICML)、国际神经信息处理系统会议(NIPS)和国际学习理论会议(COLT),重要的区域性会议主要有欧洲机器学习会议(ECML)和亚洲机器学习会议(ACML);最重要的国际学术期刊是Journal of Machine Learning Research和Machine Learning.
- 国内不少书籍包含机器学习方面的内容,例如[陆汝钤,1996].[李航,2012]是以统计学习为主题的读物. 国内机器学习领域最重要的活动是两年一次的中国机器学习大会(CCML)以及每年举行的“机器学习及其应用”研讨会(MLA).

学术期刊及国际会议

一些比较公认的相关权威刊物和会议（仅供参考）

相关权威刊物（字母序）：

- **AIJ** (Artificial Intelligence)
- **JAIR** (Journal of Artificial Intelligence in Medicine)
- **JMLR** (Journal of Machine Learning Research)
- **MLJ** (Machine Learning)
- **NCJ** (Neural Computation)
- **TKDE** (IEEE Trans Knowledge and Data Engineering)
- **TOIS** (ACM Trans Information Systems)
- **TPAMI** (IEEE Trans Pattern Analysis and Machine Intelligence)

相关权威会议（字母序）：

- **AAAI** (National Conf. AI)
- **COLT** (ACM Ann. Conf. Learning Theory)
- **ECML** (Euro. Conf. Machine Learning)
- **ICML** (Intl. Conf. Machine Learning)
- **IJCAI** (Intl. J. Conf. AI)
- **NIPS** (Ann. Conf. Neural Information Processing Systems)
- **SIGKDD** (ACM Intl. Conf. Knowledge Discovery and Data Mining)
- **UAI** (Intl. Conf. Uncertainty in AI)

一些网络资源 (1)

1. <http://machine-learning.martinsewell.com>
2. AAIL AITopics :
 - <https://aitopics.org/search>
1. Support Vector Machines:
 - <http://www.support-vector-machines.org/index.html>

一些网络资源(2)

- http://www.cs.cmu.edu/~tom/10701_sp11/lectures.shtml
 - Machine Learning (Spring 2011) @ CMU
 - Tom Mitchell
 - Video Lecture & Slides
- <https://see.stanford.edu/Course/CS229/>
 - CS229 - Machine Learning

一些网络资源(3)

- <http://www.cvpapers.com/>



Computer Vision Paper Indexes

- ICCV: 2013, 2011, 2009, 2007
- CVPR: 2015 available on CVPR website, 2014, 2013, 2012, 2011, 2010, 2009, 2008, 2007
- ECCV: 2014 **new**, 2012, 2010, 2008, 2006
- ACCV: 2012, 2010, 2007
- BMVC: 2012, BMVC papers online
- ICPR: 2008
- SIGGRAPH (Computer Vision selection): 2011, 2010
- EUROGRAPHICS (Computer Vision selection): 2011
- IJCAI (Computer Vision selection): 2011

Computer Science Paper Indexes

- IJCAI (Full list): 2011
- WWW: 2011

Computer Vision Resource

- Open Source Algorithm Implementations
- Datasets
- Forum
- CVOnline