





机器学习

单变量线性回归

模型表示

住房价格 (俄勒冈州波特兰市)

价格/千美元



监督学习

为数据中的每个示例给出“正确答案”。

回归问题

预测实值输出


	面积/平方英尺 (x)	价格/千美元 (y)
房价训练集 (俄勒冈州波特兰市)	2104	460
	1416	232
	1534	315
	852	178
	...	...

符号定义：

m 表示训练集中实例的数量

x 表示特征/输入变量


y 表示目标变量/输出变量



h 代表学习算法的解决方案或函数也称为假设


如何表示 h ?

$$h_{\theta}(x) = \theta_0 + \theta_1 x$$



单变量线性回归

(Linear regression with one variable /
Univariate linear regression)



机器学习

单变量线性回归

代价函数


训练集	面积/平方英尺 (x)	价格/千美元 (y)
	2104	460
	1416	232
	1534	315
	852	178
	...	...

假设: $h_{\theta}(x) = \theta_0 + \theta_1 x$

θ_i 表示模型参数

如何选择 θ_i ?


$$h_{\theta}(x) = \theta_0 + \theta_1 x$$



$$\theta_0 = 1.5$$

$$\theta_1 = 0$$


$$h_{\theta}(x) = 1.5 + 0 * x$$



$$\theta_0 = 0$$

$$\theta_1 = 0.5$$


$$h_{\theta}(x) = 0.5x$$



$$\theta_0 = 1$$

$$\theta_1 = 0.5$$

$$h_{\theta}(x) = 1 + 0.5x$$



想法：针对训练实例 (x, y) ，
选择 θ_0, θ_1 ，使得 $h_\theta(x)$
与 y 很接近。

$$\underset{\theta_0, \theta_1}{\text{minimize}} \quad \frac{1}{2m} \sum_{i=1}^m (h_\theta(x^{(i)}) - y^{(i)})^2$$


$$h_\theta(x^{(i)}) = \theta_0 + \theta_1 x^{(i)}$$

$$J(\theta_0, \theta_1) = \frac{1}{2m} \sum_{i=1}^m (h_\theta(x^{(i)}) - y^{(i)})^2$$

$$\underset{\theta_0, \theta_1}{\text{minimize}} \quad J(\theta_0, \theta_1)$$



代价函数



机器学习

单变量线性回归


代价函数的直观理解I

假设:

$$h_{\theta}(x) = \theta_0 + \theta_1 x$$

参数:

$$\theta_0, \theta_1$$



代价函数:

$$J(\theta_0, \theta_1) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2$$


目标: minimize $J(\theta_0, \theta_1)$
 θ_0, θ_1

简化

$$h_{\theta}(x) = \theta_1 x$$

$$(\theta_0 = 0)$$

$$\theta_1$$




$$J(\theta_1) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2$$

minimize $J(\theta_1)$
 θ_1

$$h_{\theta}(x)$$

(对于固定的参数 θ_1 , $h_{\theta}(x)$ 是关于 x 的一个函数)




$$J(\theta_1) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2$$

$$= 0$$



$$J(\theta_1)$$

($J(\theta_1)$ 是关于参数 θ_1 的一个函数)




$$\theta_1 = 1$$

$$J(\theta_1) = 0$$

$$h_{\theta}(x)$$

(对于固定的参数 θ_1 , $h_{\theta}(x)$ 是关于 x 的一个函数)




$$J(\theta_1) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2$$

$$= \frac{7}{12}$$

$$J(\theta_1)$$

($J(\theta_1)$ 是关于参数 θ_1 的一个函数)




$$\theta_1 = 0.5$$

$$J(\theta_1) = \frac{7}{12}$$

$$h_{\theta}(x)$$

(对于固定的参数 θ_1 , $h_{\theta}(x)$ 是关于 x 的一个函数)




$$J(\theta_1) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2$$

$$= \frac{7}{3} = 2.3$$



$$J(\theta_1)$$


($J(\theta_1)$ 是关于参数 θ_1 的一个函数)



$$J(\theta_1) = \frac{7}{3}$$

$$h_{\theta}(x)$$


(对于固定的参数 θ_1 , $h_{\theta}(x)$ 是关于 x 的一个函数)





$J(\theta_1)$
multi θ_1

$$J(\theta_1)$$

($J(\theta_1)$ 是关于参数 θ_1 的一个函数)




- 箭头代表损失值
- 蓝线代表预测值




可以观察到：左边模型的损失值较高，右边模型的损失值较低。

观察下面两个图：




A



B

图中所示的两组数据中，哪一组的损失值较低？



机器学习

单变量线性回归 代价函数的直 观理解II

假设: $h_{\theta}(x) = \theta_0 + \theta_1 x$

模型参数: θ_0, θ_1


代价函数: $J(\theta_0, \theta_1) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2$

目标: $\underset{\theta_0, \theta_1}{\text{minimize}} J(\theta_0, \theta_1)$

$$h_{\theta}(x)$$

(对于固定的参数 θ_0, θ_1 , $h_{\theta}(x)$ 是关于 x 的一个函数)


价格/千美元




$$h_{\theta}(x) = 50 + 0.06x$$

$$J(\theta_0, \theta_1)$$

($J(\theta_0, \theta_1)$ 是关于参数 θ_0, θ_1 的一个函数)




等高线图(contour plots/contour figure)




$$h_{\theta}(x)$$

(对于固定的参数 θ_0, θ_1 , $h_{\theta}(x)$ 是关于 x 的一个函数) ($J(\theta_0, \theta_1)$ 是关于参数 θ_0, θ_1 的一个函数)




$$J(\theta_0, \theta_1)$$




$$h_{\theta}(x)$$

(对于固定的参数 θ_0, θ_1 , $h_{\theta}(x)$ 是关于 x 的一个函数) ($J(\theta_0, \theta_1)$ 是关于参数 θ_0, θ_1 的一个函数)




$$J(\theta_0, \theta_1)$$




$$h_{\theta}(x)$$

(对于固定的参数 θ_0, θ_1 , $h_{\theta}(x)$ 是关于 x 的一个函数) ($J(\theta_0, \theta_1)$ 是关于参数 θ_0, θ_1 的一个函数)




$$J(\theta_0, \theta_1)$$





$$h_{\theta}(x)$$

(对于固定的参数 θ_0, θ_1 , $h_{\theta}(x)$ 是关于 x 的一个函数) ($J(\theta_0, \theta_1)$ 是关于参数 θ_0, θ_1 的一个函数)



$$J(\theta_0, \theta_1)$$





机器学习

单变量线性回归


梯度下降


有一些关于 θ_0, θ_1 的代价函数 $J(\theta_0, \theta_1)$

通过梯度下降算法希望得到 $\min_{\theta_0, \theta_1} J(\theta_0, \theta_1)$

梯度下降背后的思想是：

- 随机选择一个参数组合 θ_0, θ_1
- 通过持续改变 θ_0, θ_1 使得代价函数 $J(\theta_0, \theta_1)$ 数值下降，直到找到一个局部最小值。





梯度下降算法

repeat until convergence {

$$\theta_j := \theta_j - \alpha \frac{\partial}{\partial \theta_j} J(\theta_0, \theta_1) \quad (\text{for } j = 0 \text{ and } j = 1)$$

}


学习率

正确的方式：同步更新

$$\text{temp0} := \theta_0 - \alpha \frac{\partial}{\partial \theta_0} J(\theta_0, \theta_1)$$

$$\text{temp1} := \theta_1 - \alpha \frac{\partial}{\partial \theta_1} J(\theta_0, \theta_1)$$

$$\theta_0 := \text{temp0}$$

$$\theta_1 := \text{temp1}$$


错误的方式：

$$\text{temp0} := \theta_0 - \alpha \frac{\partial}{\partial \theta_0} J(\theta_0, \theta_1)$$

$$\theta_0 := \text{temp0}$$

$$\text{temp1} := \theta_1 - \alpha \frac{\partial}{\partial \theta_1} J(\theta_0, \theta_1)$$

$$\theta_1 := \text{temp1}$$



机器学习

单变量线性回归

梯度下降的直观理解


梯度下降算法

repeat until convergence {

$$\theta_j := \theta_j - \alpha \frac{\partial}{\partial \theta_j} J(\theta_0, \theta_1)$$

}


(同步更新 $j = 0$ 和 $j = 1$)



$$\theta_1 := \theta_1 - \alpha \frac{\partial}{\partial \theta_1} J(\theta_1)$$

假设: $\frac{\partial}{\partial \theta_1} J(\theta_1) > 0$

$$\theta_1 := \theta_1 - \alpha * (\text{正数})$$




$$\theta_1 := \theta_1 - \alpha \frac{\partial}{\partial \theta_1} J(\theta_1)$$

假设: $\frac{\partial}{\partial \theta_1} J(\theta_1) < 0$


$$\theta_1 := \theta_1 - \alpha * (\text{负数})$$

$$\theta_1 := \theta_1 - \alpha \frac{\partial}{\partial \theta_1} J(\theta_1)$$


如果 α 过小，梯度下降的速度会很慢。



如果 α 过大，梯度下降可能会越过最低点。它会导致无法收敛，甚至发散。



$$\theta_1 := \theta_1 - \alpha \frac{d}{d\theta_1} J(\theta_1)$$



θ_1 在局部最优的地方吗?


现在 θ_1 的值


- A. 保持 θ_1 不变
- B. 在随机的方向上改变 θ_1
- C. 往全局代价函数 $J(\theta_1)$ 最小值的方向改变 θ_1
- D. 减小 θ_1

即使学习率 α 固定不变，梯度下降也会收敛到局部最小值。

$$\theta_1 := \theta_1 - \alpha \frac{d}{d\theta_1} J(\theta_1)$$

当接近局部最小值时，梯度下降会自动缩小步长。因此，不需要随着时间的推移而减小学习率 α 。





机器学习

单变量线性回归

梯度下降的线性回归

梯度下降算法

repeat until convergence {
 $\theta_j := \theta_j - \alpha \frac{\partial}{\partial \theta_j} J(\theta_0, \theta_1)$
 (for $j = 1$ and $j = 0$)
}

线性回归模型

$$h_{\theta}(x) = \theta_0 + \theta_1 x$$

$$J(\theta_0, \theta_1) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2$$

$$\begin{aligned}
 \frac{\partial}{\partial \theta_j} J(\theta_0, \theta_1) &= \frac{\partial}{\partial \theta_j} \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2 \\
 &= \frac{\partial}{\partial \theta_j} \frac{1}{2m} \sum_{i=1}^m (\theta_0 + \theta_1 x^{(i)} - y^{(i)})^2
 \end{aligned}$$

$$j = 0 : \frac{\partial}{\partial \theta_0} J(\theta_0, \theta_1) = \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})$$

$$j = 1 : \frac{\partial}{\partial \theta_1} J(\theta_0, \theta_1) = \frac{1}{m} \sum_{i=1}^m ((h_{\theta}(x^{(i)}) - y^{(i)}) \cdot x^{(i)})$$

梯度下降算法


repeat until convergence {


$$\theta_0 := \theta_0 - \alpha \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})$$

$$\theta_1 := \theta_1 - \alpha \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) \cdot x^{(i)}$$


} 同时更新 θ_0, θ_1

}






凸函数 (*Convex function*)




$$h_{\theta}(x)$$

(对于固定的参数 θ_0, θ_1 , $h_{\theta}(x)$ 是关于 x 的一个函数) ($J(\theta_0, \theta_1)$ 是关于参数 θ_0, θ_1 的一个函数)




$$J(\theta_0, \theta_1)$$




$$h_{\theta}(x)$$

(对于固定的参数 θ_0, θ_1 , $h_{\theta}(x)$ 是关于 x 的一个函数) ($J(\theta_0, \theta_1)$ 是关于参数 θ_0, θ_1 的一个函数)




$$J(\theta_0, \theta_1)$$




$$h_{\theta}(x)$$

(对于固定的参数 θ_0, θ_1 , $h_{\theta}(x)$ 是关于 x 的一个函数) ($J(\theta_0, \theta_1)$ 是关于参数 θ_0, θ_1 的一个函数)




$$J(\theta_0, \theta_1)$$




$$h_{\theta}(x)$$

(对于固定的参数 θ_0, θ_1 , $h_{\theta}(x)$ 是关于 x 的一个函数) ($J(\theta_0, \theta_1)$ 是关于参数 θ_0, θ_1 的一个函数)




$$J(\theta_0, \theta_1)$$




$$h_{\theta}(x)$$

(对于固定的参数 θ_0, θ_1 , $h_{\theta}(x)$ 是关于 x 的一个函数) ($J(\theta_0, \theta_1)$ 是关于参数 θ_0, θ_1 的一个函数)




$$J(\theta_0, \theta_1)$$




$$h_{\theta}(x)$$

(对于固定的参数 θ_0, θ_1 , $h_{\theta}(x)$ 是关于 x 的一个函数) ($J(\theta_0, \theta_1)$ 是关于参数 θ_0, θ_1 的一个函数)




$$J(\theta_0, \theta_1)$$




$$h_{\theta}(x)$$

(对于固定的参数 θ_0, θ_1 , $h_{\theta}(x)$ 是关于 x 的一个函数) ($J(\theta_0, \theta_1)$ 是关于参数 θ_0, θ_1 的一个函数)




$$J(\theta_0, \theta_1)$$




$$h_{\theta}(x)$$

(对于固定的参数 θ_0, θ_1 , $h_{\theta}(x)$ 是关于 x 的一个函数) ($J(\theta_0, \theta_1)$ 是关于参数 θ_0, θ_1 的一个函数)




$$J(\theta_0, \theta_1)$$




$$h_{\theta}(x)$$

(对于固定的参数 θ_0, θ_1 , $h_{\theta}(x)$ 是关于 x 的一个函数) ($J(\theta_0, \theta_1)$ 是关于参数 θ_0, θ_1 的一个函数)



$$J(\theta_0, \theta_1)$$



批量梯度下降

“批量”： 梯度下降的每一步都使用所有的训练实例。