




机器学习

应用机器学习的建议

决定下一步做什么

调试一个学习算法：

假设您已经实施正则化线性回归来预测房价。

$$J(\theta) = \frac{1}{2m} \left[\sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2 + \lambda \sum_{j=1}^m \theta_j^2 \right]$$


然而，当你在一组新房子上检验你的假设时，你会发现它的预测误差大得令人无法接受。接下来你应该尝试什么？

- 获得更多的训练样本
- 尝试减少特征的数量
- 尝试获得更多的特征
- 尝试增加多项式特征 ($x_1^2, x_2^2, x_1x_2, \text{etc.}$)
- 尝试减少正则化程度 λ
- 尝试增加正则化程度 λ

机器学习诊断法：

“诊断法”的意思是：您可以运行该测试来了解学习算法是否适用，并获得有关如何最好地提高其性能的指导。

实施诊断可能需要一些时间，但这样做的确是把时间用在了刀刃上。




机器学习

应用机器学习的建议

评估一个假设

评估你的假设




$$h_{\theta}(x) = \theta_0 + \theta_1 x + \theta_2 x^2 + \theta_3 x^3 + \theta_4 x^4$$

无法推广到不在训练集中的新示例。

- x_1 = 房子的面积
- x_2 = 卧室的数量
- x_3 = 楼层的数量
- x_4 = 房屋的年龄
- x_5 = 邻居的平均收入
- x_6 = 厨房的大小
- $\vdots$
- x_{100}

评估你的假设

数据集：



线性回归的训练/测试程序

- 从训练数据中学习参数 θ （最小化训练误差 $J(\theta)$ ）
- 计算测试集误差：

$$J_{test}(\theta) = \frac{1}{2m_{test}} \sum_{i=1}^{m_{test}} (h_{\theta}(x_{test}^{(i)}) - y_{test}^{(i)})^2$$

逻辑回归的训练/测试程序


- 从训练数据中学习参数 θ
- 计算测试集误差：

$$J_{test}(\theta) = -\frac{1}{m_{test}} \sum_{i=1}^{m_{test}} y_{test}^{(i)} \log h_{\theta}(x_{test}^{(i)}) + (1 - y_{test}^{(i)}) \log h_{\theta}(x_{test}^{(i)})$$

- 误分类的比率 (0/1误分类误差) :

$$\text{err}(h_{\theta}(x), y) = \begin{cases} 1 & \text{if } h_{\theta}(x) \geq 0.5, y = 0 \\ & \text{or if } h_{\theta}(x) < 0.5, y = 1 \\ 0 & \text{otherwise} \end{cases}$$

$$\text{Test error} = \frac{1}{m_{test}} \sum_{i=1}^{m_{test}} \text{err}(h_{\theta}(x_{test}^{(i)}), y_{test}^{(i)})$$




机器学习

应用机器学习的建议

模型选择和交叉验证集

过拟合示例



$$h_{\theta}(x) = \theta_0 + \theta_1 x + \theta_2 x^2 + \theta_3 x^3 + \theta_4 x^4$$

一旦参数 $\theta_0, \theta_1, \dots, \theta_4$ 拟合某些数据集（训练集），则在该数据上测量的参数误差（训练误差 $J(\theta)$ ）可能低于实际的泛化误差。

模型选择

1. $h_{\theta}(x) = \theta_0 + \theta_1 x$
2. $h_{\theta}(x) = \theta_0 + \theta_1 x + \theta_2 x^2$
3. $h_{\theta}(x) = \theta_0 + \theta_1 x + \dots + \theta_3 x^3$
- $\vdots$
10. $h_{\theta}(x) = \theta_0 + \theta_1 x + \dots + \theta_{10} x^{10}$

选择 $\theta_0 + \dots \theta_5 x^5$


该模型的泛化能力如何？报告测试集误差 $J_{test}(\theta^{(5)})$ 。

问题： $J_{test}(\theta^{(5)})$ 可能是泛化误差的乐观估计，即我们的额外参数（ d = 多项式的次数）是根据测试集进行拟合的。

评估你的假设

数据集：

	面积	价格	
	2104	400	
	1600	330	
60%	2400	369	训练集
	1416	232	
	3000	540	
	1985	300	
	1534	315	
20%	1427	199	交叉验证集
	1380	212	
20%	1494	243	测试集



$$(x^{(1)}, y^{(1)})$$

$$(x^{(2)}, y^{(2)})$$

$$\vdots$$

$$(x^{(m)}, y^{(m)})$$

$$(x_{cv}^{(1)}, y_{cv}^{(1)})$$

$$(x_{cv}^{(2)}, y_{cv}^{(2)})$$

$$\vdots$$

$$(x_{cv}^{(m_{cv})}, y_{cv}^{(m_{cv})})$$

$$(x_{test}^{(1)}, y_{test}^{(1)})$$

$$(x_{test}^{(2)}, y_{test}^{(2)})$$

$$\vdots$$

$$(x_{test}^{(m_{test})}, y_{test}^{(m_{test})})$$

训练/验证/测试误差

训练误差：

$$J_{train}(\theta) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2$$

交叉验证集误差：

$$J_{cv}(\theta) = \frac{1}{2m_{cv}} \sum_{i=1}^{m_{cv}} (h_{\theta}(x_{cv}^{(i)}) - y_{cv}^{(i)})^2$$

测试集误差：


$$J_{test}(\theta) = \frac{1}{2m_{test}} \sum_{i=1}^{m_{test}} (h_{\theta}(x_{test}^{(i)}) - y_{test}^{(i)})^2$$

模型选择

1. $h_{\theta}(x) = \theta_0 + \theta_1 x$
2. $h_{\theta}(x) = \theta_0 + \theta_1 x + \theta_2 x^2$
3. $h_{\theta}(x) = \theta_0 + \theta_1 x + \cdots + \theta_3 x^3$
- $\vdots$
10. $h_{\theta}(x) = \theta_0 + \theta_1 x + \cdots + \theta_{10} x^{10}$

挑选 $\theta_0 + \theta_1 x_1 + \cdots + \theta_4 x^4$

估计测试集的泛化误差 $J_{test}(\theta^{(4)})$




机器学习


应用机器学习的建议

诊断偏差和方差


偏差和方差



高偏差
(欠拟合)



恰好正确






高方差
(过拟合)

偏差和方差


训练误差:
$$J_{train}(\theta) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2$$

交叉验证集误差:
$$J_{cv}(\theta) = \frac{1}{2m_{cv}} \sum_{i=1}^{m_{cv}} (h_{\theta}(x_{cv}^{(i)}) - y_{cv}^{(i)})^2$$



诊断偏差与方差

假设你的学习算法表现不如预期 ($J_{cv}(\theta)$ 或 $J_{test}(\theta)$ 高)。这是偏差问题还是方差问题？



偏差 (欠拟合)


$J_{train}(\theta)$ 将会很高

$$J_{cv}(\theta) \approx J_{train}(\theta)$$

方差 (过拟合)

$J_{train}(\theta)$ 将会很低

$$J_{cv}(\theta) \gg J_{train}(\theta)$$



机器学习


应用机器学习的建议

正则化和偏差/方差

正则化线性回归


模型: $h_{\theta}(x) = \theta_0 + \theta_1 x + \theta_2 x^2 + \theta_3 x^3 + \theta_4 x^4$

$$J(\theta) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2 + \frac{\lambda}{2m} \sum_{j=1}^m \theta_j^2$$




大的 λ

高偏差 (欠拟合)



适中的 λ
“恰好正确”



小的 λ
高方差 (过拟合)

$\lambda = 10000. \theta_1 \approx 0, \theta_2 \approx 0, \dots$

$h_{\theta}(x) \approx \theta_0$

选择正则化参数 λ

避免偏差和方差

$$h_{\theta}(x) = \theta_0 + \theta_1 x + \theta_2 x^2 + \theta_3 x^3 + \theta_4 x^4$$

$$J(\theta) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2 + \frac{\lambda}{2m} \sum_{j=1}^m \theta_j^2$$

$$J_{train}(\theta) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2$$

$$J_{cv}(\theta) = \frac{1}{2m_{cv}} \sum_{i=1}^{m_{cv}} (h_{\theta}(x_{cv}^{(i)}) - y_{cv}^{(i)})^2$$

$$J_{test}(\theta) = \frac{1}{2m_{test}} \sum_{i=1}^{m_{test}} (h_{\theta}(x_{test}^{(i)}) - y_{test}^{(i)})^2$$

选择正则化参数 λ

模型: $h_{\theta}(x) = \theta_0 + \theta_1 x + \theta_2 x^2 + \theta_3 x^3 + \theta_4 x^4$

$$J(\theta) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2 + \frac{\lambda}{2m} \sum_{j=1}^m \theta_j^2$$

1. 尝试 $\lambda = 0$
2. 尝试 $\lambda = 0.01$
3. 尝试 $\lambda = 0.02$
4. 尝试 $\lambda = 0.04$
- $\lambda = 0.08$
- $\vdots$
12. 尝试 $\lambda = 10$


选择 $\theta^{(5)}$. 测试误差:


偏差/方差作为正则化参数 λ 的函数

$$J(\theta) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2 + \frac{\lambda}{2m} \sum_{j=1}^m \theta_j^2$$

$$J_{train}(\theta) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2$$

$$J_{cv}(\theta) = \frac{1}{2m_{cv}} \sum_{i=1}^{m_{cv}} (h_{\theta}(x_{cv}^{(i)}) - y_{cv}^{(i)})^2$$





机器学习



应用机器学习的建议

学习曲线


学习曲线

$$J_{train}(\theta) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2$$



$$J_{cv}(\theta) = \frac{1}{2m_{cv}} \sum_{i=1}^{m_{cv}} (h_{\theta}(x_{cv}^{(i)}) - y_{cv}^{(i)})^2$$




高偏差



如果学习算法存在高偏差，那么获取更多训练数据（本身）并没有多大帮助。




高方差




如果学习算法存在高方差，获取更多训练数据可能会有所帮助。

$$h_{\theta}(x) = \theta_0 + \theta_1 x + \dots + \theta_{100} x^{100}$$


(和小的 λ)



你训练一个学习算法，发现它在测试集上的误差很高。绘制学习曲线，并获得下图。算法是否存在高偏差、高方差或两者都不存在？



A. 高偏差 B. 高方差 C. 两者都不



机器学习

应用机器学习的建议

决定下一步做什么


调试学习算法：

假设您已经实施正则化线性回归来预测房价。然而，当您在一组新房屋中检验您的假设时，您会发现它的预测误差大得令人无法接受。接下来你应该尝试什么？

- 获得更多的训练样本 → 解决高方差
- 尝试减少特征的数量 → 解决高方差
- 尝试获得更多的特征 → 解决高偏差
- 尝试增加多项式特征 ($x_1^2, x_2^2, x_1x_2, \text{etc}$) → 解决高偏差
- 尝试减少正则化程度 λ → 解决高偏差
- 尝试增加正则化程度 λ → 解决高方差


神经网络和过度拟合

“小”神经网络
(参数越少;
越容易出现欠拟合)



计算成本更低

“大”神经网络
(参数越多,
越容易出现过拟合)



计算成本更高

使用正则化 (λ) 来解决过度拟合问题。