




机器学习


支持向量机SVM:Supported Vector Machine
支持向量回归SVR:Supported Vector Regression

支持向量机

优化目标

逻辑回归的另一种观点

$$h_{\theta}(x) = \frac{1}{1 + e^{-\theta^T x}}$$



如果 $y = 1$, 我们希望 $h_{\theta}(x) \approx 1, \theta^T x \underline{\gg} 0$


如果 $y = 0$, 我们希望 $h_{\theta}(x) \approx 0, \theta^T x \underline{\ll} 0$

逻辑回归的另一种观点


代价函数: $-(y \log h_{\theta}(x) + (1 - y) \log(1 - h_{\theta}(x)))$

$$= -y \log \frac{1}{1 + e^{-\theta^T x}} - (1 - y) \log(1 - \frac{1}{1 + e^{-\theta^T x}})$$

如果 $y = 1$ (希望 $\theta^T x \gg 0$):



如果 $y = 0$ (希望 $\theta^T x \ll 0$):



支持向量机

逻辑回归:

$$\min_{\theta} \frac{1}{m} \left[\sum_{i=1}^m y^{(i)} \left(-\log h_{\theta}(x^{(i)}) \right) + (1 - y^{(i)}) \left(-\log(1 - h_{\theta}(x^{(i)})) \right) \right] + \frac{\lambda}{2m} \sum_{j=1}^n \theta_j^2$$

超参数：提前设定的

支持向量机:

$$\min_{\theta} \frac{1}{m} \sum_{i=1}^m \left[y^{(i)} \text{cost}_1(\theta^T x^{(i)}) + (1 - y^{(i)}) \text{cost}_0(\theta^T x^{(i)}) \right] + \frac{\lambda}{2m} \sum_{j=1}^n \theta_j^2$$

惩罚项：调节两个cost的贡献作用

$$\min_{\theta} C \sum_{i=1}^m \left[y^{(i)} \text{cost}_1(\theta^T x^{(i)}) + (1 - y^{(i)}) \text{cost}_0(\theta^T x^{(i)}) \right] + \frac{1}{2} \sum_{j=1}^n \theta_j^2$$


支持向量机假设

$$\min_{\theta} C \sum_{i=1}^m \left[y^{(i)} \text{cost}_1(\theta^T x^{(i)}) + (1 - y^{(i)}) \text{cost}_0(\theta^T x^{(i)}) \right] + \frac{1}{2} \sum_{j=1}^n \theta_j^2$$

假设:

$$h_{\theta}(x) = \begin{cases} 1 & \text{if } \theta^T X \geq 0 \\ 0 & \text{otherwise} \end{cases}$$

↓
正负号
2分



机器学习


支持向量机

大间距

large margin

支持向量机

$$\min_{\theta} C \sum_{i=1}^m \left[y^{(i)} \text{cost}_1(\theta^T x^{(i)}) + (1 - y^{(i)}) \text{cost}_0(\theta^T x^{(i)}) \right] + \frac{1}{2} \sum_{j=1}^n \theta_j^2$$



如果 $y = 1$, 我们希望 $\theta^T x \geq 1$ (不只是 ≥ 0)


如果 $y = 0$, 我们希望 $\theta^T x \leq -1$ (不只是 < 0)

支持向量机决策边界

$$\min_{\theta} C \sum_{i=1}^m \left[y^{(i)} \text{cost}_1(\theta^T x^{(i)}) + (1 - y^{(i)}) \text{cost}_0(\theta^T x^{(i)}) \right] + \frac{1}{2} \sum_{j=1}^n \theta_j^2$$

当 $y^{(i)} = 1$:


$$\theta^T x^{(i)} \geq 1$$




当 $y^{(i)} = 0$:

$$\theta^T x^{(i)} \leq -1$$

$$-1 \leq \theta^T x^{(i)} \leq 1$$




支持向量机决策边界：线性可分的情况




大间距分类器

存在异常值的大间距分类器

所有类别与决策边界的间距（距离）最大



兼容少数的错误、离群样本，或者去噪





机器学习

支持向量机

大间距分类背后的数学（可选）

最小化代价函数、
最大化分类间距

向量内积



$$u = \begin{bmatrix} u_1 \\ u_2 \end{bmatrix} \quad v = \begin{bmatrix} v_1 \\ v_2 \end{bmatrix}$$

u, v : 两个向量

$$\|u\| = \sqrt{u_1^2 + u_2^2} \quad \|v\| = \sqrt{v_1^2 + v_2^2}$$

$\|u\|$: 向量 u 的长度

p : 向量 v 到 u 的投影长度

$$u^T v = [u_1 \ u_2] \begin{bmatrix} v_1 \\ v_2 \end{bmatrix}$$

$$= u_1 \times v_1 + u_2 \times v_2$$

$$= p \times \|u\|$$

$$= v^T u$$

$$= \|u\| \|v\| \cos \langle u, v \rangle$$

支持向量机决策边界

$$\min_{\theta} \frac{1}{2} \sum_{j=1}^n \theta_j^2 = \frac{1}{2} (\theta_1^2 + \theta_2^2) = \frac{1}{2} \left(\sqrt{\theta_1^2 + \theta_2^2} \right)^2 = \frac{1}{2} \|\theta\|^2$$


$$\text{s.t. } \theta^T x^{(i)} \geq 1 \quad \text{if } y^{(i)} = 1$$

$$\theta^T x^{(i)} \leq -1 \quad \text{if } y^{(i)} = 0$$

简化: $n = 2, \theta_0 = 0$

参数向量

分线边界



$$\theta^T x^{(i)} = p^{(i)} \cdot \|\theta\|$$
$$= \theta_1 \cdot x_1^{(i)} + \theta_2 \cdot x_2^{(i)}$$

支持向量机决策边界

$$\min_{\theta} \frac{1}{2} \sum_{j=1}^n \theta_j^2$$


$$\text{s.t. } \underline{p^{(i)} \cdot \|\theta\| \geq 1} \quad \text{if } \underline{y^{(i)} = 1}$$

$$p^{(i)} \cdot \|\theta\| \leq -1 \quad \text{if } y^{(i)} = -1$$


其中, $p^{(i)}$ 是 $x^{(i)}$ 在向量 θ 上的投影。

简化: $\theta = 0$

θ 是决策边界的法向量




如果 $p^{(1)} \cdot \|\theta\| \geq 1$, 那么 $\|\theta\|$ 非常小



如果 $p^{(1)} \cdot \|\theta\| \geq 1$, 那么 $\|\theta\|$ 非常大

支持向量机假设




机器学习

支持向量机

核函数 I

非线性决策边界



预测 $y = 1$ 如果


$$\theta_0 + \theta_1 x_1 + \theta_2 x_2 + \theta_3 x_1 x_2 \\ + \theta_4 x_1^2 + \theta_5 x_2^2 + \dots \geq 0$$

$$\theta_0 + \theta_1 f_1 + \theta_2 f_2 + \theta_3 f_3 \dots$$

$$f_1 = x_1, f_2 = x_2, f_3 = x_1 x_2, f_4 = x_1^2, f_5 = x_2^2$$

是否有不同/更好的特征选择 $f_1, f_2, f_3, \dots$?

核函数



给定 x , 根据与地标 $l^{(1)}, l^{(2)}, l^{(3)}$ 的距离
计算新特征

$$\|x - l^{(i)}\|^2 = \sum_{j=1}^n (x_j - l_j^{(i)})^2$$

$$f_1 = \text{similarity}(x, l^{(1)}) = \exp\left(-\frac{\|x - l^{(1)}\|^2}{2\sigma^2}\right)$$

$$f_2 = \text{similarity}(x, l^{(2)}) = \exp\left(-\frac{\|x - l^{(2)}\|^2}{2\sigma^2}\right)$$

$$f_3 = \text{similarity}(x, l^{(3)}) = \exp\left(-\frac{\|x - l^{(3)}\|^2}{2\sigma^2}\right)$$

核函数

核函数与相似性

$$f_1 = \text{similarity}(x, l^{(1)}) = \exp\left(-\frac{\|x - l^{(1)}\|^2}{2\sigma^2}\right)$$

如果 $x \approx l^{(1)}$:

$$f_1 = \exp\left(-\frac{\|x - l^{(1)}\|^2}{2\sigma^2}\right) \approx 1$$



如果 x 远离 $l^{(1)}$:

$$f_1 = \exp\left(-\frac{\|x - l^{(1)}\|^2}{2\sigma^2}\right) \approx 0$$



例子:

$$l^{(1)} = \begin{bmatrix} 3 \\ 5 \end{bmatrix}, \quad f_1 = \exp\left(-\frac{\|x - l^{(1)}\|^2}{2\sigma^2}\right)$$



$$\sigma^2 = 1$$




$$\sigma^2 = 0.5$$



$$\sigma^2 = 3$$






预测 $y = "1"$ 时, 当

$$\theta_0 + \theta_1 f_1 + \theta_2 f_2 + \theta_3 f_3 \geq 0$$


$$\theta_0 = -0.5, \theta_1 = 1, \theta_2 = 1, \theta_3 = 0$$

高斯核的公式是由 $\text{similarity}(x, l^{(1)}) = \exp\left(-\frac{\|x - l^{(1)}\|^2}{2\sigma^2}\right)$ 给出的。


下图显示了当 $\sigma^2 = 1$ 时, $f_1 = \text{similarity}(x, l^{(1)})$ 的曲线图。




当 $\sigma^2 = 0.25$ 时, 下列哪个是 f_1 的曲线图?




A.




B.



C.



D.




机器学习

支持向量机

核函数 II

选择地标




给定 x :

$$f_i = \text{similarity}(x, l^{(i)})$$
$$= \exp\left(-\frac{\|x - l^{(i)}\|^2}{2\sigma^2}\right)$$

预测 $y = 1$ 如果 $\theta_0 + \theta_1 f_1 + \theta_2 f_2 + \theta_3 f_3 \geq 0$

从哪里获取 $l^{(1)}, l^{(2)}, l^{(3)}, \dots$?



带有核函数的支持向量机

给定 $(x^{(1)}, y^{(1)}), (x^{(2)}, y^{(2)}), \dots, (x^{(m)}, y^{(m)})$,

选择 $l^{(1)} = x^{(1)}, l^{(2)} = x^{(2)}, \dots, l^{(m)} = x^{(m)}$.

给定一个例子 x :

$$f_1 = \text{similarity}(x, l^{(1)})$$

$$f_2 = \text{similarity}(x, l^{(2)})$$

...

训练示例: $(x^{(i)}, y^{(i)})$

$$f_1^{(i)} = \text{sim}(x^{(i)}, l^{(1)})$$

$$x^{(i)} \Rightarrow f_2^{(i)} = \text{sim}(x^{(i)}, l^{(2)})$$

$$\vdots \leftarrow f_i^{(i)} = \text{sim}(x^{(i)}, l^{(1)}) = \exp\left(-\frac{0^2}{2\sigma^2}\right) = 1$$

$$f_m^{(i)} = \text{sim}(x^{(i)}, l^{(m)})$$

带有核函数的支持向量机

假设: 给定 x , 计算特征 $f \in \mathbb{R}^{m+1}$

如果 $\theta^T f \geq 0$ 预测“ $y=1$ ”

训练:

$$\min_{\theta} C \sum_{i=1}^m y^{(i)} cost_1(\theta^T f^{(i)}) + (1 - y^{(i)}) cost_0(\theta^T f^{(i)}) + \frac{1}{2} \sum_{j=1}^n \theta_j^2$$



支持向量机参数:


$C (= \frac{1}{\lambda})$. C 较大时: 低偏差, 高方差。
 C 较小时: 高偏差, 低方差。

σ^2 σ^2 较大时: 特征 f_i 变化更加平滑。
高偏差, 低方差。

$$\exp\left(-\frac{\|x - l^{(i)}\|^2}{2\sigma^2}\right)$$

σ^2 较小时: 特征 f_i 变化不够平滑。
低偏差, 高方差。





机器学习

支持向量机

使用支持向量机

使用 SVM 软件包(如 liblinear, libsvm, ...)求解参数 θ .

需要明确说明:

选择参数 C .

选择核参数（相似性函数）：

E.g. 没有核参数(“线性核函数”)

如果 $\theta^T x \geq 0$ 预测 “ $y = 1$ ”

高斯核:

$$f_i = \exp\left(-\frac{\|x - l^{(i)}\|^2}{2\sigma^2}\right), \text{ where } l^{(i)} = x^{(i)}.$$

需要选择 σ^2 .

核（相似性）函数：

```
function f = kernel(x1,x2)
```

$$f = \exp\left(-\frac{\|\mathbf{x1} - \mathbf{x2}\|^2}{2\sigma^2}\right)$$

```
return
```

注意：在使用高斯核之前，请进行特征缩放。

核函数的其他选择

注意：并非所有的相似性函数 $\text{similarity}(x, l)$ 都是有效的核函数。
(需要满足名为“**Mercer's Theorem**”的技术条件，以确保 SVM 软件包的优化运行正确且不会出现偏离）。


提供许多现成的核函数：

- 多项式核函数：

$$K(x, l) = (X^T l + m)^d, d = 1, 2, \dots, N$$

- 更加深奥的核函数：字符串核函数, 卡方核函数, 直方图交集核函数, ...

多类别分类



$$y \in \{1, 2, 3, \dots, K\}$$

许多 SVM 软件包已经内置了多类分类功能.

否则, 使用一对多的方法。(训练 K 个支持向量机, 其中一个用于和其他的区分 $y = i$, 其中 $i = 1, 2, \dots, K$, 得到了 $\theta^{(1)}, \theta^{(2)}, \dots, \theta^{(K)}$ 选取 $(\theta^{(i)})^T x$ 最大的类别 i 。

逻辑回归与支持向量机

n = 特征数 ($x \in \mathbb{R}^{n+1}$), m = 训练样本数

如果 n 非常大(相对于 m):

使用逻辑回归, 或不带内核的支持向量机 (“线性核函数”)

如果 n 非常小, m 是中间值:


使用带有高斯核的支持向量机

如果 n 非常小, m 非常大:

创建/添加更多特征, 然后使用逻辑回归或无核函数的支持向量机

神经网络可能在大多数情况下都能正常工作, 但训练速度可能较慢。

假设您使用训练了一个高斯内核的支持向量机，它在训练集上学习了以下决策边界：



你觉得支持向量机欠拟合了，你应该试着增加或减少 C 吗？或者增加或减少 σ^2 ？

A. 降低 C ，增加 σ^2 B. 降低 C ，降低 σ^2 C. 增加 C ，增加 σ^2 D. 增加 C ，降低 σ^2