

A、认为不可控

A1、认为未来的 AI 会欺骗人类

在智源人工智能大会上，AI 教父 Hinton 做了《two paths to intelligence》的演讲。他从对计算架构和原理的分析中，得出了自己结论「人造神经网络将比人脑更智能」，这比他原先想象地快很多。并且，Hinton 提出以下观点：

1、信息操纵和虚假信息：大型 AI 模型可以被用来生成逼真的虚假信息、伪造视频和音频内容，从而引发虚假信息的传播和操纵。这可能导致社会不稳定、舆论混乱和信任危机。

2、隐私和数据滥用：大型 AI 模型需要大量的数据进行训练，而这些数据往往涉及个人隐私。如果这些数据被滥用或不当处理，可能导致个人隐私泄露和滥用。

3、自动化和就业影响：大型 AI 模型的快速发展和应用可能导致某些传统工作岗位的自动化，从而对就业市场产生影响。某些工作可能会被 AI 取代，需要人们转变职业或提升技能以适应新的就业需求。

4、偏见和不平等：大型 AI 模型的训练数据可能存在偏见或不平等，这可能导致 AI 系统在决策、推荐和评估等方面存在偏见和不公正。这可能加剧社会的不平等现象，并对弱势群体产生负面影响。

为了应对这些威胁，需要采取一系列的措施，包括制定合适的法律和伦理框架，确保透明度和可解释性，加强数据隐私保护，推动公平和多样化的 AI 技术发展，并进行跨学科的研究和合作，以解决 AI 所带来的各种挑战和风险。

A2、认为当前的 AI 已经具备威胁人类的能力

很多关于大模型的评论都涉及到：人类又一次陷入“科林格里奇困境”。Hinton 如今对 AI 的情绪，与晚年时期的诺贝尔和爱因斯坦如出一辙。诺贝尔发明炸药原本是为了提高开矿、修路等工程的效率，当他发现自己的发明被投入到战场上后，其自责达到了顶点，这也促使他后来创立了诺贝尔奖。清华大学人工智能国际治理研究院副院长梁正认为，在新技术兴起时，人类通常会面临所谓的“科林格里奇困境”——技术尚未出现，监管者无法提前预测其影响并采取行动；而当它已经出现时，采取行动往往为时已晚或成本过高。幸运的是，迄今为止，人类通过不断适应新技术的发展而调整治理手段，一次次走出了“科林格里奇困境”。“比如在汽车大规模上市前，人们就为其安装上了刹车，之后也一直在完善汽车的安全性，为其提供各类检测和认证，甚至在汽车发明 100 多年后，人们还在为其安全‘打补丁’——装上安全气囊。”梁正说。不过，他也承认，这一次 AI 的来势汹汹似乎与以往有些不同，“速度太快了。”比如，训练了几个月的 ChatGPT 的性能提升比过去几年迭代都要快，这意味着生成式 AI 大模型可以在几周内将潜在风险转变为实存风险，进而对人类社会造成不可估量的影响。

A3、大模型在数据安全和应用安全上的威胁

大数据协同安全技术国家工程研究中心发布了《大语言模型提示注入攻击安全风险分析报告》。报告指出，当前主流 LLM 可以通过自然语言提示进行调整，但其内部功能机制仍然不透明且不可评估。这种特性导致 LLM 很容易受到有针对性的对抗性提示（样本）攻击，且难以缓解。该报告提示目前大语言模型面临的风险类型包括提示注入攻击、对抗攻击、后门攻击、数据污染、软件漏洞、隐私滥用等多种风险，也带来了相关的伦理和社会风险，如：歧视

或负面言论、虚假信息、隐私资料/侵犯版权、有害的建议。在大语言模型面临的安全威胁中，提示注入（PI）攻击因利用有害提示覆盖大语言模型的原始指令，具有极高危害性，也被全球性安全组织 OWASP 列为大语言模型十大安全威胁之首。研究者展示了通过检索和 API 调用功能对 LLM 发动注入攻击。这些 LLM 可能会处理从 Web 检索到的有毒内容，而这些内容包含由对手预先注入的恶意提示。研究证明，攻击者可以通过上述方法间接执行此类 PI 攻击。到目前为止，提示注入大多是由系统用户直接执行的，试图引发意外行为。

B、认为可控

B1、从能源的角度分析 AI 可控性

根据《纽约客》杂志的报道，OpenAI 的 ChatGPT 聊天机器人每天消耗超过 50 万千瓦时的电力，用于处理约 2 亿个用户请求，相当于美国家庭每天用电量的 1.7 万多倍。随着生成式人工智能的广泛应用，预计到 2027 年，整个人工智能行业每年将消耗 85 至 134 太瓦时的电力，这显示了 AI 技术对电力资源的巨大需求。

随着人工智能技术的发展，对芯片的需求急剧增加，进而带动了电力需求的激增。全球数据中心市场的耗电量已经从十年前的 100 亿瓦增加到如今的 1000 亿瓦水平。根据美国 Uptime Institute 的预测，到 2025 年，人工智能业务在全球数据中心用电量中的占比将从 2% 增加到 10%。

生成式人工智能带来了许多创新，但也伴随着处理性能和功耗方面的高昂成本。马斯克曾预计，未来两年可能从“缺硅”转变为“缺电”，电力短缺可能会成为人工智能发展的阻碍。他表示，电力短缺可能会像最近的芯片短缺一样对科技和汽车行业造成严重影响。

太原理工大学校长孙宏斌在著名期刊《焦耳》发表论文，探讨了中国未来发展电力能源的方向。同时，该工作的第一作者英国剑桥大学博士生秦鑫在接受《中国科学报》采访时表示，如果有一天人工智能诞生了自我意识，能够如科幻片中描述的那样对人类社会产生威胁，那么电力系统将是人类最后的防线。因为没有电，人工智能的一切都无从谈起，而电力系统的复杂程度，更令今天的人工智能暂时难以攻破。

同样的，马斯克的关注点也在大模型训练和调用时所需要耗费的电力上，他担心按现在“人工智能消耗的算力每 6 个月就增加 10 倍”的速度下去，短缺的将是电力。

B2、对人类工作机会的威胁不必担心

百度 CEO 李彦宏在第七届世界智能大会上发表演讲。“我不担心大模型会导致人类工作机会减少。”5 月 18 日，百度 CEO 李彦宏在第七届世界智能大会上发表了题为《大模型改变人工智能》的演讲，“人类最大的危险，最大的不可持续，并不是创新带来的不确定性。相反，我们停止创新，不发明不创造不进步，按照惯性走下去，所带来的各种各样不可预知的风险，才是人类最大的威胁。”李彦宏认为，大数据、大算力、大模型，导致了智能涌现。同时，人工智能发生了方向性改变，从辨别式 AI 走向生成式 AI，大模型也重新定义了人机交互，重新定义营销和客服。

在接受央视《对话》栏目采访时，李彦宏表示：“我觉得人工智能发展比我想象中更慢。人工智能已经被提出快 70 年了，可能每过 10 年左右，就有一波人很兴奋说，我们终于要实现通用人工智能了。后来发现其实不是那么回事，情况比想象的要复杂。”

英伟达 CEO 黄仁勋在斯坦福的访谈演讲中表示，如果生成式 AI 逐渐取代编程的话，编程技术将可能变得不那么有价值了。但是周鸿祎予以了反驳，他认为，程序员热十年内不会减弱，AI 时代更需要计算机专家和程序员。

B3、认为目前 AI 能力不足

颜宁出席在香港理工大学举行的“理大高等研究院大会”并进行主题演讲，讲解蛋白质的前沿研究及其可能对痛症药物开发的深远影响。演讲后她回答了现场师生的提问，其中谈到了 AI。颜宁还回答了当前 AI 热点问题——“科学家的工作能否被 AI 取代”。颜宁说，虽然当前 AI 发展很快，只要它无法回答“宇宙起源”和“生命起源”两个问题，任何研究工作就无法被取代。末了，颜宁还补充说：“我们会保住自己的工作”，引发全场掌声。并且，颜宁在微博上多次表示，目前的 AI 只是数据驱动的，在一些人类尚未发现的知识领域，AI 由于缺少训练数据，会表现的很差。同时，颜宁表示，为了提高 AI 的真正实力，她和她的团队愿意公开数据供 AI 研究人员使用。

同样的，联合国教科文组织 AI 伦理特设专家组专家、中国科学院自动化研究所 AI 伦理与治理中心主任曾毅认为，以 ChatGPT 为代表的大模型是“看似智能的信息处理”，与智能的本质没有关系。“人们之所以觉得它很厉害，因为它的回答满足了人们的需求，如果这些回答来自于一个人，你会觉得他太聪明了。但如果你跟它说‘我很不高兴’，它说‘那我怎么能让你高兴一些’，这让人觉得它似乎理解了情感，而实际上它只是建立了文本之间的关联。”曾毅认为，目前的 AI 系统与人类智能的区别在于，大模型没有“我”的概念，没有自我就无法区分自我和他人，就无法换位思考，无法产生共情，也就无法真正理解情感。

北京瑞莱智慧科技有限公司 AI 治理研究院院长张伟强表示，当前的大模型仍属于第二代 AI，其主要特征为以深度学习为技术、以数据驱动为模式。这使得它在决策链路和逻辑上具有天然的不确定性，即便是模型开发者，也无法准确预知模型的输出结果。当语言大模型“信口开河”时，不能认为是出现了所谓的“自我意识”，而仅仅是技术缺陷使然。

B4、制定行业规范，防范潜在危险

在 1 月 24 日举办的腾讯科技向善创新节 2024“大模型安全与伦理专题论坛”上，腾讯发布了大模型安全白皮书《大模型安全与伦理研究报告 2024：以负责任 AI 引领大模型创新》，并邀请业界专家进行圆桌研讨。

在谈及大模型带来的挑战时，该报告主要从两个方面进行了讨论。

第一个方面是数据隐私。该报告简短的总结了当前对机器学习模型进行攻击并意图窃取数据隐私的方法，比如：对抗攻击、后门攻击等。

第二个方面是大模型安全保护问题。首先，该报告指出，如果一家公司研发的大模型被其它公司盗用，则会出现版权问题，被盗用者产生巨大损失，并会影响未来对人工智能技术研究的积极性。其次，大模型的能力可能被滥用。当大模型的能力被恶意利用时，需要根据模型版权明确责任。目前学术界有提出模型水印概念，用来判断模型版权来源，然而模型水印存在降低大模型泛化能力或者容易被微调消除等缺点，因此探索更加可靠的大模型版权保护方法是未

来解决的关键挑战。最后，该报告指出大模型的内容安全。由于模型的黑箱性，其可解释性较差、存在输出不可控的问题（例如大模型幻觉：觉是指大模型生成无意义或与用户提示词不对应的内容，通常包含与用户输入冲突幻觉、上下文冲突幻觉和事实冲突幻觉。这种幻觉会给用户带来理解偏差甚至误导用户产生错误决策。）。因此大模型可能会产生不符合事实、含有偏见、不符合伦理规范、不符合法律规定等有问题的回答。这对模型的内容安全造成了严重的挑战。

为此，该报告倡议构建大模型安全框架。大模型安全框架聚焦于大模型生产研发应用过程中的安全风险问题，包括大模型内生安全及应用安全以及因为大模型的不合理应用引发的人工智能应用决策失控风险。

对于因滥用或者恶意使用大模型而导致的安全风险，主要由国家法律法规和行业管理规范来进行监管规范。国家网信办等七部门于 2023 年 7 月 10 日联合公布了《生成式人工智能服务管理暂行办法》，自 2023 年 8 月 15 日起施行。该办法就生成式人工智能可能面临的安全问题提出了一系列明确的约束规范，比如在第四条明确指出“提供和使用生成式人工智能服务，应当遵守法律、行政法规，尊重社会公德和伦理道德。从 2021 年开始，为了保障数据安全、个人隐私、伦理道德、以及从跨国市场规范、AI 平权等多项目标考虑，欧盟就开始推进《人工智能法案》。各大企业也在技术和产品形态上不断追求更安全的大模型，比如 OpenAI 就在积极提高其训练的大模型的安全性。

对于大模型生产研发流程中出现的安全风险问题，应该由大模型研发团队及安全团队共同关注，通过安全评估等机制来保障大模型的应用达到安全目标。该报告从近几年隐私保护、对抗样本等技术出发，提供了一些对数据进行保护的技术建议，并且，给大模型安全框架设计提供了一些宏观的开发流程和规范。该报告指出，大模型安全作为一个新兴的安全领域，多家头部企业、安全团队均在积极探索潜在安全问题及风险收敛的解决方案。然而，目前行业内还未形成成熟完善的解决方案，仍处于探索阶段。为此，我们围绕大模型生产研发流程设计了大模型安全框架，从全局视角剖析大模型生产应用全生命后期存在的安全风险问题，为大模型的研发及应用提供安全指导，致力于构建安全、可靠、稳定、可信的大模型应用。把安全措施落实到具体的研发，训练，测试，部署发布环节是提升大模型安全的行业共识，通过对大模型安全进行多个角度的测评、安全验证分析，该报告总结了以下几方面实践过程中的工作经验供行业同仁参考。

- (1) **Prompt 安全测评。**我们搭建了 Prompt 安全检测平台，专门用于模拟攻击者的行为，以掌握大模型在 Prompt 风险场景下的安全性和表现。Prompt 安全测评的目的是在大模型上线前提前自动化挖掘潜在的多种原生安全风险，并在上线过程中辅助业务进行风险收敛，从而确保大模型生成的回复内容符合《生成式人工智能服务管理暂行办法》等各类法律法规。并在此基础上形成自动化攻击样本生成能力，自动化风险研判能力。
- (2) **红蓝对抗演习。**通过多轮红蓝对抗演习，能够对大模型安全防御体系中的数据安全、攻击防护、应急响应机制进行安全有效性验证，并帮助业务在上线前发现和收敛潜在的内外网资产安全风险。
- (3) **大模型源代码安全防护实践。**大模型源代码保护的重要性主要体现在资产维度，研发周期维度，研发环境维度。从经验上看，大模型研发到上线分为两个大的阶段，上线前和上线后。上线前需要重点做好研发环境的安全加固，主要分为客户端加固、链路层加固、服务层加固以及基础设施加固。上线后主要是运营阶段，风险面主要

在于对外暴露的资产，例如网页、接口、APP、小程序等。这块的防护主要是分为用户客户端加固、业务接入层安全防护两个步骤进行。

- (4) **大模型基础设施漏洞安全防护方案。**数据的采集和清洗、大模型的训练和推理过程中，都会大量使用外部开源或自研的系统或框架以提高工作效率，这些工具成为大模型工作流中的基础设施。若这些效率工具存在安全漏洞，将会使得模型本身以及训练代码和数据变得不安全，存在被攻击者窃取或篡改的风险。为了保证大模型的安全生产，我们必须建立机制以提前发现和消除潜在的漏洞。
- (5) **大模型价值对齐。**随着 AI 模型的能力日益更加强大，如何让其行为和目的跟人类的价值观、偏好、伦理原则、真实意图之间实现协调一致，这个被称为人机价值对齐的问题变得越来越重要。价值对齐对于确保人类与人工智能协作过程中的信任与安全至关重要，已经成为 AI 治理领域的一项关键任务，是大模型实现稳健发展和提升竞争力的必由之路。界和研究界积极探索实现大模型价值对齐的多种措施，包括人类反馈强化学习、可扩展监督方法、训练数据干预、可解释 AI 方法、对抗测试、治理措施等等。TIME 杂志将美国 AI 公司 anthropic 开发的 AI 价值对齐技术“原则型 AI”（constitutional AI）评选为 2023 年三大 AI 创新之一（另外两个分别为多模态 AI、文生视频技术），这足以表明价值对齐已然成为 AI 领域的核心方向，其重要性正越来越被认识到。

最后，该报告给出大模型安全与伦理未来趋势，主要包括以下六方面内容。

- (1) **数据安全、隐私泄露、抗攻击能力提升等问题是现有大模型应用面临的真实挑战。**解决这些问题的技术手段还存在一定的局限性，如数据来源验证不足、数据加密技术的性能开销、防御效果与模型性能之间的权衡等。如何在保证大模型性能的同时，提高数据使用的安全性，提升隐私保护效果，防止越狱攻击、提示注入攻击等，这些都是亟待解决的问题，有赖于业界持续探索、总结并分享最佳实践做法。总之，对抗性人工智能技术与防御策略之间的竞赛将加剧，为了应对对抗性攻击和操纵等恶意行为，模型需要被设计为更加具有鲁棒性。
- (2) **从整体上对 AI 大模型的安全风险进行建模，系统化地构建安全评估系统是大模型安全领域的未来发展方向。**这将最大程度地确保大模型应用是在符合社会价值与应用价值方面同步进行。当前，Anthropic 已经采纳并批准了模型开发应用的“负责任扩展政策”（responsible scaling policy, RSP），通过一系列的技术和组织协议来管理开发日益更加强大的 AI 系统的风险，其核心思路包括对 AI 安全等级进行建模。OpenAI 在人事斗争风波平息后，对其 AI 安全团队做出调整，针对当前模型、前沿模型（即新一代模型）、超级智能模型分别搭建不同的安全团队，分别是系统安全团队、准备团队和超级对齐团队；并公布了最新的模型危害等级框架，用来指导前沿模型开发中的安全性。微软、谷歌则通过扩大漏洞奖励计划和红队测试（Red teaming）方式激励研究人员发现针对人工智能系统的攻击场景，进而增强 AI 模型的安全性。
- (3) **增强模型透明度和可解释性。**研究模型的可解释性，提高模型的透明度既是未来 AI 的发展方向，也能帮助提升 AI 模型的安全性。未来的人工智能模型可能会融入更先进的 XAI 技术。这将涉及开发能够为其决策提供易于理解的理由的模型，使其更加透明和值得信赖。通过解释模型的决策过程，我们可以更好地理解模型的行为，及时发现潜在的安全隐患，并采取相应的措施进行修复。例如，LIME 局部可解释性（Local interpretable model-agnostic explanations）和 SHAP（Shapley Additive

Explanations) 等算法已经在提高模型可解释性方面取得了一定的成果。而且 Anthropic 的研究表明, 可解释性 AI 也是可以扩展的, 并非随着模型规模的持续扩大而变得一无是处。

- (4) **人机价值对齐和伦理嵌入设计 (ethics by design) 的理念将变得越来越重要。**在谈论人工智能伦理和人工智能伦理框架多年之后的今天, 人们越来越意识到需要更加务实的思路, 将抽象的伦理原则转变为具体的工程化实践。因此, AI 系统将越来越多地以伦理原则为指导进行设计, 从而实现伦理嵌入设计 (ethics by design)。无论是 AI 价值对齐还是伦理嵌入设计, 都需要人们发展新的更加务实的 AI 伦理框架及其实践指南。同时, 模型的价值对齐需要考虑不同的文化和社会价值, 超越那种一刀切的思路。此外, 在 AI 对齐领域, 随着模型能力的持续提升, 未来能力更强的新一代 AI 模型将可能需要新的对齐技术和策略, 目前主流 AI 企业都在积极探索如何实现对前沿 AI 模型甚至未来的超级智能的有效对齐和控制。大模型未来发展对先进的安全措施的需求将越来越强烈: 安全功能如故障保护和紧急停机开关, 将变得更加复杂, 确保模型在行为不可预测或危险时可以被控制或停用。
- (5) **人工智能监管立法和国际治理合作将得到进一步推进。**随着大模型在各行业的广泛应用, 政府和监管机构对大模型安全和伦理的关注也在不断加强, 欧盟已经就制定全球首个人工智能法案达成了最终的立法共识, 英国政府召开全球首个 AI 安全峰会并建立专门的 AI 安全研究所推进 AI 安全相关研究和工作, 美国政府出台的关于安全、可信 AI 的行政命令提出 AI 安全相关的措施。未来立法和监管措施将给大模型安全和伦理的研究和实践提供更进一步的指导。此外, 随着大模型的加快发展, AI 安全和治理领域的国际合作将迎来新的阶段, 迈向更加务实的方向, 确保 AI 技术的开源开放和普惠发展, 同时有效管控全球性安全风险。
- (6) **在大模型安全和伦理研究中, 跨学科合作是一个重要趋势。**随着大模型在各个领域的应用, 安全和伦理问题的复杂性也在不断提高。因此, 未来大模型安全和伦理研究需要吸收多领域的知识和技术, 形成跨学科的研究团队, 共同解决不断升级的复杂安全和伦理问题, 确保负责任的、安全可控的 AI 发展应用。

一些与会专家对该报告的有效性进行了以下评价:

腾讯安全平台部负责人 杨勇:

AI 技术将深刻地影响着我们工作及生活方式, 如何保障人工智能安全是我们当前迫切的责任。要把这一理念转变为具体的行动需要有标准的制定, 健全的安全管理机制, 有效的实践经验带来的思路启发等。在该报告当中, 我们把过往实践的安全积累与前沿洞察的变化融在一起, 希望能够在在大模型快速发展中提供一个安全视角, 探明存在的问题与挑战, 有哪些积极的应对措施, 以及未来在整体安全, 数据安全, 监管立法, 跨学合作方面寻找新的理念, 为行业同仁提供一份参考。

清华大学深圳国际研究生院教授/博导: 夏树涛

随着大模型能力的不断增强和适用范围的延伸, 其在金融、医疗、广告、营销等商业领域的应用, 使得大模型中存在的微小安全隐患会造成巨大损害, 因而大模型安全问题引起了广泛关注。此报告从大模型的发展趋势、面临的机遇与挑战出发, 阐明了大模型的安全框架与实践方案, 最后点明了大模型安全的未来发展趋势。报告的叙述内容层次分明, 详尽地给出了大模型安全与伦理的调研与分析, 可以作为大模型安全领域研究的重要参考。